

基于自然驾驶先验与极值风险校准的自动驾驶长尾安全测试方法

蒋拯民^{1,2,3}, 李嘉昊¹, 李明鑫¹, 李慧云⁴, 潘毅³, 汪建平⁵

1 (香港城市大学计算机科学系, 香港特别行政区 999077)

2 (香港城市大学物质科学研究院 (福田), 深圳市 518045)

3 (深圳理工大学计算机科学与人工智能学院, 深圳市 518055)

4 (深圳理工大学算力微电子学院, 深圳市 518055)

5 (香港城市大学计算学院, 香港特别行政区 999077)

摘要: 真实道路风险具有显著稀有性, 使自动驾驶系统在长尾场景中的安全表现难以仅依靠道路测试数据回放进行有效量化。针对这一问题, 本文提出一种基于自然驾驶先验与极值风险校准的自动驾驶长尾安全测试方法。该方法以开源高速公路自然驾驶数据为例, 面向跟驰和切入两类代表性场景构建事件级风险变量, 并利用广义极值模型从自然驾驶风险尾部分布中外推安全关键阈值。在此基础上, 本文采用高斯 Copula 平滑建模独立尾部事件的场景条件联合分布, 并通过条件扩散模型学习对抗车的连续动作行为, 从而将有限离线尾部观测转换为可复现且可采样的自然驾驶尾部测试分布。进一步地, 本文在场景条件与扩散潜变量联合空间中执行子集模拟, 估计被测自动驾驶系统超过人类驾驶校准风险阈值的条件概率和风险重现周期。实验表明, 广义极值模型良好刻画跟驰和切入风险变量的高风险尾部, 扩散先验能够保持主要动作与交互变量的自然性。相较直接 Monte Carlo 基线, 子集模拟在相同概率对象下以更少闭环评估获得一致估计: 被测自动驾驶系统在跟驰和切入长尾场景下的安全关键条件概率分别为 0.0025 和 0.0068, 对应重现周期分别为 2366.41 km 和 16392.32 km, 约为相同阈值下自然驾驶基线的 7.89 倍和 5.46 倍。本文将有限长尾观测转化为以人类驾驶尾部风险为统计参照、可闭环执行并支持概率推断的长尾测试分布, 为自动驾驶系统长尾风险的安全评估提供方法支撑。

关键词: 自动驾驶; 安全测试; 极值理论; 扩散模型; 子集模拟
中图分类号: TP391

Long-Tail Safety Testing for Autonomous Driving with Naturalistic Driving Priors and Extreme-Value Risk Calibration

JIANG Zhengmin^{1,2,3}, LI Jiahao¹, LI Mingxin¹, LI Huiyun⁴, PAN Yi³, WANG Jianping⁵

1 (Department of Computer Science, City University of Hong Kong, Hong Kong, China)

2 (Matter Science Research Institute (Futian), City University of Hong Kong, Shenzhen, China)

3 (College of Computer Science and Artificial Intelligence, Shenzhen University of Advanced Technology, Shenzhen, China)

4 (College of Computability Microelectronics, Shenzhen University of Advanced Technology, Shenzhen, China)

5 (College of Computing, City University of Hong Kong, Hong Kong, China)

Corresponding Author: WANG Jianping. College of Computing, City University of Hong Kong, Hong Kong, China. Email: jianwang@cityu.edu.hk.

Abstract: Safety-critical risks in real-world are highly rare, making it difficult to quantify the safety performance of autonomous driving systems (ADS) in long-tail scenarios using road-test data replay alone. To address this issue, this study proposes a long-tail safety testing method for ADS based on naturalistic driving priors and extreme-value risk calibration. Using open-source highway naturalistic driving data, the study constructs event-level risk variables for two representative scenarios, car-following and cut-in, and extrapolates safety-critical thresholds from the tail distribution of naturalistic driving risk using a generalized extreme-value model. Moreover, a Gaussian Copula is used to smooth the joint distribution of scenario conditions from independent tail events, and a conditional diffusion model learns the continuous action behavior of adversarial vehicles, thereby converting limited offline tail observations into a reproducible and sampleable long-tail distribution. Subset simulation is further performed in the joint space of scenario conditions and diffusion latents to estimate the conditional probability and risk return period for the tested ADS exceeding the human-driving-calibrated risk threshold. Experiments show that the generalized extreme-value model characterizes the high-risk tails of car-following and cut-in risk variables well, and that the diffusion prior preserves the naturalness of key action and interaction variables. Compared with direct Monte Carlo, subset simulation obtains consistent estimates with fewer evaluations under the same probability target: the safety-critical conditional probabilities of the tested ADS in car-following and cut-in long-tail scenarios are 0.0025 and 0.0068, respectively, corresponding to return periods of 2366.41 km and 16392.32 km, approximately 7.89 and 5.46 times the naturalistic driving baselines under the same thresholds. Overall, this paper converts limited long-tail observations into a closed-loop executable testing distribution that uses human-driving tail risk as a statistical reference and supports probabilistic inference, providing methodological support for ADS safety assessment.

Key words: Autonomous Driving; Safety Testing; Extreme Value Theory; Diffusion Model; Subset Simulation

Funding: This project is supported by the Hong Kong Research Grants Council under General Research Fund (Grant No. 11219624).

1 引言

自动驾驶系统的风险水平不仅取决于常规交通场景中的平均性能，更取决于其在低频、高风险长尾场景中的行为响应^[1;2]。由于真实道路中的安全关键事件极为稀少，单纯依赖道路测试或离线回放难以在有限预算内充分暴露被测系统的高风险行为边界，也难以量化其进入安全关键状态的概率。

为提高长尾风险暴露效率，现有研究重点关注基于仿真场景生成的安全测试方法。例如，AdvSim 和 KING 分别通过背景车辆扰动搜索与可微分运动学优化诱发被测系统失效^[3;4]；TrafficGen、DriveSceneGen 等方法通过学习交通先验提高场景多样性与危险性^[5;6]；近年来，扩散模型进一步被用于可控交通仿真^[7;8;9;10]。此外，面向感知测试的风险场景生成也从因果因素组合角度揭示了自动驾驶模块的脆弱性^[11]。在高速公路变道切入等典型交互中，赵祥模等利用 BN-AM-SeqGAN、TsGAN 等生成式 AI 模型泛化危险切入测试场景^[12;13]。上述方法提高了危险样本的发掘与测试效率，但其主要目标仍是生成更容易触发失效的样本；若生成分布偏离自然驾驶尾部行为，则难以给出相对于自然驾驶尾部行为分布的概率解释。

自然驾驶数据为长尾风险评估提供了必要的统计参照。通过学习真实车辆的运动模式，

可以使仿真测试在碰撞率、近失率、速度和车距等统计量上接近自然驾驶环境，从而构造更合理的对抗场景^[14;15;16]。例如，将自然驾驶分布与重要性采样或强化学习结合，则能够在保留相对于原始采样分布的概率解释的同时，提高安全关键事件暴露效率^[17;18]。然而，自然驾驶数据本质上是离线观测数据，即有限的长尾片段并不能直接构成可重复采样、可闭环执行的测试扰动。因此仅回放经验尾部事件，则测试覆盖范围受限，若直接对驾驶行为进行对抗优化，又容易破坏人类驾驶行为的自然性。因此，需要将自然驾驶尾部事件转化为既保留尾部交互语义、又具有可采样性的尾部行为测试分布。

实践中，自动驾驶安全测试需要进一步估计被测 ADS 在长尾分布下进入安全关键状态的概率。为此，有必要将连续交互轨迹转化为可比较的事件级风险变量，并确定何种风险水平可被视为安全关键；碰撞时间（time-to-collision, TTC）、车头时距（time headway, THW）和避免碰撞减速度（deceleration rate to avoid collision, DRAC）等代理安全度量虽能刻画局部交互危险性^[19]，但若直接采用固定经验阈值，则难以反映不同逻辑场景中自然驾驶风险尾部的统计差异。此外，高风险事件即便在筛选后的长尾分布中也依然稀疏，传统失效概率估计方法（如直接 Monte Carlo 采样）需要大量评估预算；研究者常用的代理模型与加速测试方法通常依赖低维参数空间或有限离线危险样本集合^[20]，在高维测试空间下容易受到采样效率与概率解释性的限制。

综上所述，现有研究虽然分别从危险场景生成、自然驾驶数据利用和加速测试等角度提高了长尾风险暴露效率，但是风险事件的定义往往缺少自然驾驶尾部分布参照，生成测试样本的分布语义与人类长尾行为之间缺少明确对应，稀有事件概率估计又难以在高维闭环测试空间中高效完成。换言之，自动驾驶长尾安全测试的核心挑战不只是生成更多危险场景，而是如何将自然驾驶数据中的尾部风险样本转化为可执行、可采样的闭环测试分布，从而在具有人类驾驶统计参照的长尾测试分布下，评估 ADS 以多大概率进入安全关键状态。

为此，本文基于 *highD* 自然驾驶数据集^[21]，提出了一种融合极值理论、扩散模型和子集模拟的自动驾驶长尾风险测试与概率评估框架，如图 1 所示。




图 1 驾驶风险标定与自然先验驱动的长尾风险测试框架

Fig. 1 Long-tail risk testing framework driven by driving-risk calibration and naturalistic priors

该方法以跟驰与切入两类高速公路代表性逻辑场景为例，首先利用 *highD* 事件级风险变量的广义极值分布反解具有人类驾驶统计参照的安全关键阈值；其次基于独立尾部事件的场景条件联合建模与条件扩散动作先验，构建可采样、可复现且保持自然驾驶行为约束的尾部测试分布；最后在场景条件与扩散潜变量联合空间中执行闭环子集模拟，估计被测 ADS 达到人类长尾风险等级的条件概率，并进行按风险暴露量归一化的分析。

本文的主要贡献如下：

- (1) **人类尾部风险标定：**面向跟驰与切入两类交互事件构建事件级风险变量，基于尾部样本拟合极值长尾模型，并外推人类驾驶校准的安全关键阈值，从而将多维代理安全度量统一映射为具有尾部概率语义的风险基准；
- (2) **自然尾部分布构建：**从长尾驾驶事件中提取场景条件，采用高斯 Copula 平滑近似尾部条件联合分布，并通过条件扩散模型学习目标车辆连续动作先验，将有限离线尾部观测扩展为可采样且保持自然驾驶行为约束的测试分布；
- (3) **闭环长尾概率估计：**在场景条件与扩散潜变量联合空间中应用子集模拟，通过高效的闭环仿真层次递进以逼近安全关键区域，估计 ADS 达到设定风险阈值的条件概率，并

进一步转换为风险强度和重现周期。

2 方法

本节围绕自然驾驶长尾风险度量展开，首先通过极值理论（extreme value theory, EVT）标定人类驾驶尾部风险阈值，识别安全关键测试条件；随后融合高斯 Copula、条件扩散模型与子集模拟，生成可采样、可复现的闭环测试场景，并实现 ADS 长尾风险概率估计。

2.1 驾驶事件筛选与长尾风险校准

长尾风险测试需要具有自然驾驶统计含义的参照基准，本文采用 *highD* 开源数据集^[21]作为自然驾驶行为来源。参考风险驾驶空间提取中的事件筛选原则^[22]，本文选取跟驰和切入两类代表性功能场景。前者刻画车距压缩和前车制动引发的纵向追尾风险，后者刻画相邻车道车辆并入后对受扰车辆所形成的横纵向耦合风险。后文以 $e \in \{\text{cf}, \text{ci}\}$ 分别表示跟驰与切入事件类型。

在事件抽取阶段，本文首先对原始轨迹进行行驶方向归一化和物理异常过滤，仅保留小客车交互且语义明确的原始驾驶片段。具体对于跟驰事件，要求主车在连续时间片段内具有同一前车，两车同车道比例不低于 80%，且中位跟车间距大于 0.5 m。对于切入事件，检测目标车辆由相邻车道并入目标车道的过程，并匹配切入后最近的受扰车辆；要求换道前后具有稳定车道片段，跨线后至少有 2.0 s 轨迹重叠，且切入后两车同车道比例不低于 70%。

随后，本文将每段交互轨迹压缩为可排序的事件级风险变量。记 $\tau_{a:b} = \{s_{\text{ego}}^t, s_{\text{tar}}^t\}_{t=a}^b$ 为时间区间 $[a, b]$ 内主车与目标车的交互轨迹片段，默认计分片段记为 $\tau = \tau_{0:T}$ ，其中目标车在跟驰场景中为前车，在切入场景中为切入车。具体针对跟驰事件，本文先逐个计算代理安全指标，再采用同一 softmax pooling 算子聚合为事件级分量。由此得到纵向跟驰风险得分

$$Y_{\text{long}}(\tau) = \mathbf{w}_{\text{long}}^\top \mathbf{r}_{\text{long}}(\tau) + \lambda_C C(\tau) + \lambda_N N(\tau) + \lambda_B B(\tau) \quad (1)$$

其中， $\mathbf{r}_{\text{long}}(\tau)$ 为经归一化和时序池化后的纵向代理安全度量向量，包含 TTC、THW、跟车间距和 DRAC 等分量； $\mathbf{w}_{\text{long}}$ 为对应权重向量； $C(\tau)$ 、 $N(\tau)$ 和 $B(\tau)$ 分别表示碰撞、近碰撞和急制动强度； λ_C 、 λ_N 和 λ_B 为相应权重。

对于切入事件，目标车跨越车道线后的时刻记为 t_{cutin} 。切入后的纵向风险仍按式 (1) 计算，但计分片段改为 $\tau_{t_{\text{cutin}}:T}$ 。横向附加风险用于刻画目标车向主车所在车道快速并入的迫近程度，即先由横向剩余距离 $d_\perp^t$ 与非负横向接近速度 $v_\perp^t$ 估计横向到达时间 $\Delta t_\perp^t = d_\perp^t / \max(v_\perp^t, \epsilon_v)$ ，再对 t_{cutin} 后短时段内的 $1/\max(\Delta t_\perp^t, \epsilon_L)$ 采用与纵向代理度量一致的时序池化和尺度归一化，得到横向风险项 $L_{\text{lat}}(\tau; t_{\text{cutin}})$ 。于是，对形成有效切入的轨迹，切入事件风险得分为

$$Y_{\text{cutin}}(\tau) = Y_{\text{long}}(\tau_{t_{\text{cutin}}:T}) + \lambda_L L_{\text{lat}}(\tau; t_{\text{cutin}}) \quad (2)$$

其中， λ_L 为横向风险权重， ϵ_v 和 ϵ_L 为数值下界。有效切入要求目标车形成横向重叠、持续接近并保持在目标车道，且切入后位于主车前方。后文统一用 $Y_e(\tau)$ 表示事件级风险得分， x 表示与 Y_e 同一尺度上的原始风险取值：当 $e = \text{cf}$ 时， x 是 Y_{long} 的取值；当 $e = \text{ci}$ 时， x 是 Y_{cutin} 的取值。

考虑到安全关键事件对应于 $Y_e(\tau)$ 分布右端的低频高风险长尾区域，为此本文引入极值理论刻画 *highD* 人类驾驶风险分布的尾部，并由目标超越概率反解获得 Y_e 的安全关键阈值。具体设事件类型 e 下的 *highD* 人类驾驶风险样本为 $\mathcal{Y}_e = \{Y_{e,i}\}_{i=1}^n$ ，并在该样本上选取高风险尾部建模阈值 u_e 。根据 Pickands–Balkema–de Haan 定理^[23;24]，当 u_e 足够高时，超出量 $Y_e - u_e \mid Y_e > u_e$ 可由广义帕累托分布（generalized Pareto distribution, GPD）近似。令 $\hat{\alpha}_e = n^{-1} \sum_{i=1}^n \mathbb{I}\{Y_{e,i} > u_e\}$ 为样本经验超阈率，则事件类型 e 的人类驾驶尾部生存函数可

写为

$$Q_e(x) = \Pr(Y_e > x) \approx \hat{\alpha}_e \begin{cases} (1 + \xi_e(x - u_e)/\beta_e)^{-1/\xi_e}, & \xi_e \neq 0, \\ \exp[-(x - u_e)/\beta_e], & \xi_e = 0, \end{cases} \quad x > u_e \quad (3)$$

式 (3) 中, ξ_e 和 β_e 分别为 GPD 的形状参数和尺度参数; $Q_e(x)$ 表示同类人类驾驶事件风险超过原始风险取值 x 的尾部概率。因此, $Q_e(x)$ 越小, 说明该取值在人类驾驶尾部越罕见。

在实际长尾分布拟合中, u_e 由均值剩余寿命、参数稳定性、QQ/PP 图、尾部生存函数拟合效果及阈值敏感性共同确定, 并要求超阈样本量满足最低稳定性约束。得到 Q_e 后, 本文用 $S_e(x) = -\log Q_e(x)$ 定义自然驾驶数据校准的极值风险得分。该变换不改变 Y_e 的原始风险排序, 而是将不同事件类型的原始风险值转换为“在人类驾驶中的罕见程度”的无量纲尺度。为了将该连续风险得分进一步转化为安全关键事件判别条件, 需要给定一个可解释的目标罕见程度。本文用目标超越概率 π_e^* 表示这一目标: 其含义是某一风险阈值平均每多少个事件或每多少暴露里程被超过一次; 若采用事件级重现周期 m^* , 则 $\pi_e^* = 1/m^*$ 。

给定 π_e^* 后, 原始风险空间中的安全关键阈值 $x_e^* = \inf\{x : Q_e(x) \leq \pi_e^*\}$ 可由式 (3) 直接反解为

$$x_e^* = \begin{cases} u_e + \frac{\beta_e}{\xi_e} \left[\left(\frac{\hat{\alpha}_e}{\pi_e^*} \right)^{\xi_e} - 1 \right], & \xi_e \neq 0, \\ u_e + \beta_e \log \left(\frac{\hat{\alpha}_e}{\pi_e^*} \right), & \xi_e = 0, \end{cases} \quad (4)$$

$$\gamma_e^* = S_e(x_e^*)$$

其中, x_e^* 是直接作用于事件级风险得分 Y_e 的原始风险阈值; γ_e^* 是同一阈值映射到长尾分布模型的极值风险阈值。由此, 本小节先用 highD 样本估计 Y_e 的右尾生存函数, 再把给定重现周期转化为目标超越概率 π_e^* , 最后通过 GPD 反解得到原始风险阈值 x_e^* 及其极值风险阈值 γ_e^* 。后续 ADS 闭环测试将以 $Y_e \geq x_e^*$ (或等价的 $S_e(Y_e) \geq \gamma_e^*$) 作为安全关键事件判别条件。

2.2 场景条件建模与条件扩散生成

第 2.1 节通过 EVT 筛选自然驾驶尾部事件, 为自动驾驶在长尾空间下的评估提供了初始数据来源。但这些事件仍是数量有限的原始回放轨迹, 且将初始状态、人工驾驶动作与主车响应耦合在一起, 难以直接形成 ADS 闭环测试所需的连续、可控且可重复采样的输入。因此, 本节首先从尾部事件中提取低维场景条件, 并给出跟驰与切入两类场景的具体定义; 随后对场景条件进行联合分布拟合, 最后在给定场景条件下应用条件扩散模型生成细粒度的目标车时序动作轨迹。图 2 概括了从尾部场景条件分布中采样并通过条件扩散动作生成成长尾测试场景的流程。本节主要刻画其中的场景条件分布与目标车动作生成模型。

具体而言, 场景条件由初始状态和目标车辆行为语义分量组成: 在扩散模型中, 它作为条件输入以调制动作生成过程; 在场景仿真中, 其初始状态分量用于设置主车与目标车的初始位置、速度等相对运动关系; 行为语义分量用于约束生成动作所对应的制动、速度变化或切入过程。沿用第 2.1 节的记号, ego 表示主车, tar 表示目标车, 其在跟驰场景中为前车, 在切入场景中为切入车。对于跟驰场景, 7 维场景条件向量定义为

$$\mathbf{o}_{cf} = [v_{x,ego}^0, g_0, \Delta v_x^0, a_{x,tar}^0, \Delta v_{x,tar}^T, a_{x,tar}^{\min}, \tau_{b,tar}]^T \in \mathbb{R}^7 \quad (5)$$

式中, 上标 0 表示仿真初始时刻, T 表示生成时域终末时刻, 此时目标车的动作序列为纵向加加速度 (jerk), 生成时域长度为 $H = 125$ 帧。 $g_0 = x_{tar}^0 - x_{ego}^0 - \frac{1}{2}(L_{ego} + L_{tar})$ 为初始纵向相对距离, $\Delta v_x^0 = v_{x,ego}^0 - v_{x,tar}^0$ 为初始纵向相对速度, $\Delta v_{x,tar}^T = v_{x,tar}^T - v_{x,tar}^0$ 为前车速度变化量, $a_{x,tar}^{\min} = \min_{t \in [0, T]} a_{x,tar}^t$ 为前车在生成时域内的最小纵向加速度, $\tau_{b,tar} = \sum_{t=0}^T \mathbb{I}(a_{x,tar}^t < 0) \Delta t$




图2 长尾场景条件采样、条件扩散轨迹生成与闭环评估流程

Fig. 2 Long-Tail Scenario-Condition Sampling, Conditional Diffusion-Based Trajectory Generation, and Closed-Loop Evaluation Workflow

为前车制动持续时间。对于切入场景，10维场景条件向量定义为

$$\mathbf{o}_{ci} = [v_{x,ego}^0, g_0, d_y^0, \Delta v_x^0, a_{x,tar}^0, v_{y,tar}^0, a_{y,tar}^0, d_y^T, t_{cross}, \Delta v_{x,tar}^T]^\top \in \mathbb{R}^{10} \quad (6)$$

切入场景中的目标车为切入车，动作序列为二维加速度（纵向加速度和横向加速度），生成时域长度 $H = 100$ 帧。 $g_0 = x_{tar}^0 - x_{ego}^0 - \frac{1}{2}(L_{ego} + L_{tar})$ 为初始纵向相对距离， $d_y^0 = y_{tar}^0 - y_{ego}^0$ 为初始横向偏移， $\Delta v_x^0 = v_{x,ego}^0 - v_{x,tar}^0$ 为初始纵向相对速度， $d_y^T = y_{tar}^T - y_{ego}^T$ 为终端横向偏移， t_{cross} 为从初始时刻到切入车跨越车道边界的时间， $\Delta v_{x,tar}^T = v_{x,tar}^T - v_{x,tar}^0$ 为切入车速度变化量。

在上述场景条件定义下，设第 2.1 节经 POT 阈值筛选得到的第 e 类长尾事件样本集合，以及由这些长尾事件提取的场景条件样本集合为

$$\begin{aligned} \mathcal{T}_{tail}^e &= \{\tau_i : Y_e(\tau_i) > u_e\}, \\ \mathbf{o}_{e,i} &= \phi_e(\tau_i), \quad \mathcal{O}_{tail}^e = \{\mathbf{o}_{e,i} : \tau_i \in \mathcal{T}_{tail}^e\}, \end{aligned} \quad (7)$$

其中 u_e 为第 2.1 节中的 POT 尾部建模阈值； $\phi_e(\tau_i)$ 表示从轨迹 τ_i 中提取前述场景条件向量：当 $e = cf$ 时对应式 (5) 中的 $\mathbf{o}_{cf}$ ，当 $e = ci$ 时对应式 (6) 中的 $\mathbf{o}_{ci}$ 。记由 $\mathcal{O}_{tail}^e$ 拟合得到的联合分布为 $\mathcal{D}_{tail}^e$ 。进一步地，高斯 Copula（Gaussian Copula）用于刻画场景条件之间的相关结构。由此得到的 $\mathbf{o}_e \sim \mathcal{D}_{tail}^e$ 既作为扩散模型的条件输入，也作为闭环仿真的初始场景设置。

在给定 $\mathbf{o}_e$ 后，需要进一步生成符合自然驾驶行为的目标车时序动作。为此，本文采用条件扩散模型学习动作序列在场景条件下的动作分布，即未被 $\mathbf{o}_e$ 显式固定的微观动作差异由扩散潜变量 z 表达。本文采用去噪扩散概率模型（denoising diffusion probabilistic model, DDPM）学习条件动作先验，并采用去噪扩散隐式模型（denoising diffusion implicit model, DDIM）进行确定性采样。DDPM 训练阶段将高斯噪声逐步注入自然驾驶动作序列，去噪网络在场景条件约束下预测被注入的噪声；网络由特征线性调制（feature-wise linear modulation,

FiLM) 条件变换器参数化, 使 $\mathbf{o}_e$ 能够调制各层动作序列表示。模型训练样本来源于第 2.1 节事件抽取后形成的 *highD* 跟驰与切入片段。设训练样本中的自然驾驶目标车动作序列为 $\mathbf{a}_0$, 其中跟驰场景采用前车纵向加加速度序列, 切入场景采用切入车二维加速度序列; 扩散步为 k , 噪声为 $\epsilon \sim \mathcal{N}(0, I)$, 则训练目标可概括为

$$\mathcal{L}_{\text{diff}} = \mathbb{E} \left[\|\epsilon - \epsilon_\theta(\mathbf{a}_k, k, \mathbf{o}_e)\|_2^2 \right] + \lambda_0 \|\hat{\mathbf{a}}_0 - \mathbf{a}_0\|_1 + \lambda_s \sum_{h=2}^H \|\hat{\mathbf{a}}_{0,h} - \hat{\mathbf{a}}_{0,h-1}\|_1 + \mathcal{L}_{\text{ci}}, \quad (8)$$

$$\mathbf{a}_k = \sqrt{\bar{\alpha}_k} \mathbf{a}_0 + \sqrt{1 - \bar{\alpha}_k} \epsilon,$$

其中 ϵ_θ 为条件去噪网络, $\hat{\mathbf{a}}_0$ 为由噪声预测反推得到的目标车动作序列, λ_0 和 λ_s 分别控制动作重建与平滑约束。对于切入场景, $\mathcal{L}_{\text{ci}}$ 进一步约束终端横向偏移、跨线后车道保持和横向加加速度; 对于跟驰场景, 该项取零。训练阶段按记录划分训练集、验证集和测试集, 并以验证集性能进行模型选择。测试阶段从 $\mathcal{D}_{\text{tail}}^e$ 抽取尾部事件对应的场景条件, 固定模型参数, 并采用确定性 DDIM 解码:

$$\mathbf{a}_{1:H} = G_\theta(\mathbf{o}_e, z), \quad z \sim \mathcal{N}(0, I) \quad (9)$$

总之, $\mathbf{o}_e$ 决定测试场景的长尾语义和仿真初始环境, z 表达同一场景条件下未观测的自然动作差异; 在固定模型参数 θ 后, 同一 $(\mathbf{o}_e, z)$ 对应唯一的目标车动作序列。该设计在保持 EVT 筛选的自然驾驶长尾场景空间约束的同时, 实现了对自然驾驶的有限尾部样本的连续化和泛化, 为后续闭环概率估计提供批量可重复的长尾测试场景。

2.3 基于子集模拟的风险概率加速估计

第 2.2 节基于 EVT 筛选得到的尾部事件建立场景条件联合分布, 并训练条件扩散模型生成与场景条件相匹配的目标车动作序列。在此基础上, 一个 ADS 闭环测试场景输入由场景条件与扩散潜变量构成, 记为随机向量 $X = (\mathbf{o}_e, z) \sim \mathbb{P}_e$, 其中 $\mathbb{P}_e := \mathcal{D}_{\text{tail}}^e \otimes \mathcal{N}(0, I)$, 即为 $\mathbf{o}_e$ 与 z 独立抽样所诱导的联合分布; $\mathbf{o}_e$ 来自自然驾驶尾部场景条件分布, z 表示该场景条件下未显式固定的动作差异。给定 X 后, 目标车动作序列按式 (9) 生成, 且 z 在该次闭环仿真中保持固定, 被测 ADS 随后在高保证仿真环境 $\mathcal{M}_{\text{ADS}}$ 中作出闭环响应。相应的闭环轨迹及风险得分定义为

$$\begin{aligned} \tau_{\text{ADS}}(X) &= \mathcal{M}_{\text{ADS}}(\mathbf{o}_e, \mathbf{a}_{1:H}(X)), \\ Y_e^{\text{ADS}}(X) &= Y_e(\tau_{\text{ADS}}(X)), \quad R_e(X) = S_e(Y_e^{\text{ADS}}(X)) \end{aligned} \quad (10)$$

其中, $Y_e^{\text{ADS}}(X)$ 表示被测 ADS 闭环轨迹在原始风险尺度上的事件级风险得分; $R_e(X)$ 为经 $S_e(\cdot)$ 转换后的极值风险得分, 用于表征该闭环风险在人类驾驶尾部分布中的罕见程度。 Y_e 沿用第 2.1 节中的事件级原始风险变量: 跟驰场景对应式 (1) 中的 Y_{long} , 切入场景对应式 (2) 中的 Y_{cutin} ; $S_e(\cdot)$ 由式 (3) 的尾部生存函数构造, 并与式 (4) 中 $\gamma_e^* = S_e(x_e^*)$ 的极值风险尺度保持一致。本节的估计目标是 ADS 在 $\mathbb{P}_e$ 分布下达到安全关键事件阈值的条件发生概率:

$$\begin{aligned} p_{\text{ADS},e} &= \Pr_{X \sim \mathbb{P}_e} (R_e(X) \geq \gamma_e^*) \\ &= \Pr_{X \sim \mathbb{P}_e} (Y_e^{\text{ADS}}(X) \geq x_e^*) \end{aligned} \quad (11)$$

其中 x_e^* 和 γ_e^* 分别为第 2.1 节通过 GPD 外推得到的原始风险阈值和极值风险阈值。等价地, 最终失效域可写为 $F_\star = \{X : R_e(X) \geq \gamma_e^*\}$ 。

需要强调的是, $\mathbb{P}_e$ 已经不是自然驾驶全分布, 而是由 POT 筛选后的尾部场景条件分布与扩散潜变量共同构成的长尾测试分布。本文的失效域 $F_\star$ 进一步要求闭环 ADS 风险达到第 2.1 节由人类驾驶重现水平外推得到的安全关键阈值, 因此对应于长尾测试空间内部更加

稀疏的安全关键风险子域。直接 Monte Carlo 采样虽然不改变目标分布，但在有限闭环仿真预算下往往难以命中足够的安全关键样本，导致估计方差较大。为在保持同一概率对象的前提下提高测试效率，本文在 X 空间中采用子集模拟^[25;26]，从而将估计 F_* 的稀有概率转化为若干中间阈值下的条件采样问题。在第 k 层有 N 个样本 $\{X_i^{(k)}\}_{i=1}^N$ ，将其风险得分的经验 $(1 - p_0)$ 分位数记为 b_k ，并构造中间事件 $F_k = \{X : R_e(X) \geq b_k\}$ ，其中 p_0 为预设条件概率水平。每层保留得分最高的 $p_0 N$ 个精英样本，并以这些样本为起点生成服从 $\mathbb{P}_e(\cdot | F_k)$ 的下一层条件样本。子集模拟过程在第 ℓ 层终止。若经验阈值已经达到安全关键水平 ($b_\ell \geq \gamma_e^*$)，则当前层可直接用于估计最终失效域：

$$\hat{p}_{\text{ADS},e} = p_0^\ell \frac{1}{N} \sum_{i=1}^N \mathbb{I}\{R_e(X_i^{(\ell)}) \geq \gamma_e^*\} \quad (12)$$

式 (12) 估计的是 $p_{\text{ADS},e}$ ，即 ADS 在 $\mathbb{P}_e$ 所定义尾部测试分布下达到安全关键阈值的条件概率。

为进一步与自然驾驶基准进行同一口径比较，本文将上述条件概率转换为单位风险暴露量下的安全关键风险强度。交通安全评价中的风险暴露量通常指车辆行驶里程、测试时长或事件机会数等用于归一化事件发生次数的分母；本文实验采用与 *highD* 全车辆里程一致的暴露口径。由于安全关键阈值由 *highD* 人类驾驶风险尾部标定，且 $\mathbb{P}_e$ 复现了同类尾部事件的场景条件分布和目标车动作， $\hat{p}_{\text{ADS},e}$ 可解释为同类长尾暴露条件下进入安全关键域的比例。记事件类型 e 在 *highD* 中的风险暴露量为 $\mathcal{E}_e^{\text{HD}}$ ，则 ADS 安全关键风险强度可由第 2.2 节长尾事件集合 $\mathcal{T}_{\text{tail}}^e$ 直接换算为

$$\hat{\lambda}_{\text{ADS},e} = \hat{p}_{\text{ADS},e} \frac{|\mathcal{T}_{\text{tail}}^e|}{\mathcal{E}_e^{\text{HD}}}. \quad (13)$$

当 $\mathcal{E}_e^{\text{HD}}$ 取里程时， $\hat{\lambda}_{\text{ADS},e}$ 的单位为每千米， $1/\hat{\lambda}_{\text{ADS},e}$ 可解释为平均重现里程。

综上，本小节在自然驾驶尾部统计约束下，将人类驾驶极值风险阈值、条件扩散场景生成与闭环子集模拟统一到 ADS 安全关键概率估计流程中，即以 *highD* 人类驾驶尾部重现水平为校准基准，在可类比的测试分布上估计被测 ADS 的条件风险概率及单位暴露风险强度，并提高稀疏安全关键事件的闭环评估效率。

3 实验与结果

实验围绕跟驰和切入两类 *highD* 高速公路驾驶事件展开，重点讨论：人类驾驶风险尾部能否稳定标定安全关键阈值，条件扩散先验生成的尾部测试分布是否保持自然驾驶统计特征，以及子集模拟能否在闭环仿真中有效估计 ADS 达到该阈值的条件概率。被测策略采用 *highway-env* 中的智能驾驶员模型 (intelligent driver model, IDM)，其作用是提供可复现实验对象，而非推断该策略在真实道路中的无条件安全性。全部闭环仿真均以 25 Hz 执行，并使用相同的 IDM 主车参数。

表 1 *highD* 逻辑场景事件筛选结果
Table 1 Filtering results of logical scenarios from the *highD* dataset

场景类型	原始事件数	窗口剔除数	评分候选数	语义筛除数	可用驾驶事件
跟驰场景	73323	0	73323	0	73323
切入场景	4640	330	4310	404	3906

注：原始事件数来自逻辑事件抽取记录；其余统计来自固定窗口构建与风险评分流程。窗口剔除数表示无法形成统一长度评分窗口的原始逻辑事件数，语义筛除数表示已形成固定窗口但未满足切入语义检验的数量。

3.1 自然驾驶尾部风险分析

根据第 2.1 节的事件抽取与风险评分流程, *highD* 数据首先筛选出如表 1 所示的两类高速公路交互事件。跟驰场景在 5.0 s 固定窗口下保留 73323 个可用事件; 切入场景从 4640 个原始逻辑事件中得到 3906 个可用事件, 其中 330 个事件无法形成统一 4.0 s 评分窗口, 404 个候选未通过切入语义检验。

事件级风险评分后, POT-GPD 拟合结果如表 2 所示。跟驰和切入分别得到 7546 个和 399 个尾部峰值, 经验超阈率为 0.1029 和 0.1022, 说明两类场景采用了接近的尾部截断比例。但二者在 *highD* 全车辆里程口径下的自然尾部暴露强度相差较大: 跟驰尾部峰值为 0.169666/km, 切入仅为 0.008971/km。因此, 阈值标定和 ADS 评估需要分开理解: GPD 拟合的尾部极值分布模型用于在给定人类驾驶重现水平下外推安全关键阈值 x_e^* 和 γ_e^* ; 自然暴露强度则用于把该人类驾驶基线以及后续 ADS 的风险条件概率统一换算为单位里程风险强度。

表 2 POT-GPD 尾部拟合与安全关键阈值反解参数

Table 2 POT-GPD tail-fitting and safety-critical threshold inversion parameters

场景类型	n_u	u_e	ξ_e	β_e	$\hat{\alpha}_e$	x_e^*	γ_e^*
跟驰	7546	1.6873	0.1725	0.5497	0.1029	4.7773	6.2037
切入	399	2.2216	0.0861	0.6473	0.1022	4.6859	5.5739

注: n_u 为超过 POT 阈值 u_e 的尾部样本数; ξ_e 和 β_e 分别为 GPD 形状参数和尺度参数, $\hat{\alpha}_e$ 为经验超阈率, 其分母为表 1 中对应场景的可用驾驶事件数。 x_e^* 为按 *highD* 全车辆累计里程反解的人类驾驶重现水平原始风险阈值, 其中跟驰 $L^* = 300$ km、切入 $L^* = 3000$ km; $\gamma_e^* = S_e(x_e^*)$ 为等价极值风险尺度阈值。

表 2 中的 u_e 是 POT 建模阈值, 用于选取进入 GPD 拟合的长尾样本; 闭环安全关键判定则由人类驾驶重现水平反解得到的 x_e^* 和 γ_e^* 给出。该设定避免为 TTC、车间距或 DRAC 等单一代理指标另行指定经验阈值, 而是在事件级风险变量 Y_{long} 和 Y_{cutin} 的尾部概率尺度上定义安全关键水平。具体而言, 尾部生存概率 $Q_e(x)$ 与极值风险尺度 $S_e(x)$ 的定义见式 (3), 阈值反解关系见式 (4)。其中 x_e^* 位于原始事件风险变量尺度, 直接对应 Y_{long} 或 Y_{cutin} ; $\gamma_e^* = S_e(x_e^*)$ 位于极值风险尺度, 用于后续子集模拟的失效判定。图 3 和图 4 进一步检验两类风险样本的尾部区域、GPD 拟合质量和阈值稳定性。




图 3 跟驰风险样本的 POT 筛选、GPD 拟合与阈值诊断

Fig. 3 POT and GPD Diagnostics for Car-Following Risk Samples

注: 跟驰风险变量 Y_{long} 的 POT 阈值 $u = 1.6873$, 超阈样本数 $n_u = 7546$, 经验超阈率 $\hat{\alpha} = 0.1029$ 。GPD 拟合参数为 $\xi = 0.1725$ 、 $\beta = 0.5497$; 200 次参数自助法中, Kolmogorov-Smirnov、Cramer-von Mises 和 Anderson-Darling 拟合优度检验的 p 值分别为 0.68、0.70 和 0.50。




图 4 切入风险样本的 POT 筛选、GPD 拟合与阈值诊断

Fig. 4 POT and GPD Diagnostics for Cut-in Risk Samples

注：切入风险变量 Y_{cutin} 的 POT 阈值 $u = 2.2216$ ，超阈样本数 $n_u = 399$ ，经验超阈率 $\hat{\alpha} = 0.1022$ 。GPD 拟合参数为 $\xi = 0.0861$ 、 $\beta = 0.6473$ ；200 次参数自助法中，Kolmogorov–Smirnov、Cramer–von Mises 和 Anderson–Darling 拟合优度检验的 p 值分别为 0.23、0.13 和 0.19。

图 3 和图 4 表明，两类风险样本在所选 POT 阈值以上均具有可接受的尾部拟合表现：经验生存函数与 GPD 尾部生存函数在主体尾部基本一致，均值剩余寿命、参数稳定性和 PP 诊断支持所选阈值；QQ 诊断在最远端存在有限偏差，但自助法拟合优度检验未拒绝 GPD 拟合假设。因此，两类风险变量的高风险尾部可用于后续人类驾驶校准安全关键阈值的确定。




图 5 基于人类驾驶重现水平的安全关键阈值确定

Fig. 5 Human-driving return-level-based safety-critical threshold determination

图 5 将式 (4) 中的目标重现里程 L^* 逐点代入已拟合的 POT-GPD 模型，给出 L^* 与 x_e^* 、 γ_e^* 的对应关系。两类场景中，目标重现里程越大，允许被人类驾驶超过的概率越低，因而反解得到的原始风险阈值和极值风险尺度阈值均随之升高。图中标记的跟驰 300 km 与切入 3000 km 反解点对应表 2 中的 x_e^* 和 γ_e^* ；后续闭环评估不再重新选取经验风险阈值，而是直接以这些人类驾驶重现水平标定的阈值判定 $S_e(Y_e^{\text{ADS}}) \geq \gamma_e^*$ 。

3.2 场景条件与条件扩散生成的有效性

闭环评估的输入分布为 $\mathbb{P}_e = \mathcal{D}_{\text{tail}}^e \otimes \mathcal{N}(0, I)$ ：场景条件由独立尾部事件拟合的高斯 Copula 采样，目标车动作由预训练的条件扩散模型和确定性 DDIM 解码生成。跟驰场景生成 125 步纵向 jerk 序列，对应 5.0 s 目标车运动，并将 $|\text{jerk}|$ 约束在 12 m/s^3 以内；切入场景生成 100 步二维加速度序列，对应 4.0 s 交互过程，并约束 $a_x \in [-8, 4] \text{ m/s}^2$ 、 $|a_y| \leq 4 \text{ m/s}^2$ 。

由此得到的联合采样变量维度分别为 132 和 210。因此，本节检验的不是全量自然驾驶分布拟合精度，而是尾部测试分布是否同时满足两个闭环评估前提：覆盖 EVT 尾部条件空间，并保留与风险形成直接相关的目标车运动统计。




图 6 跟驰尾部测试分布的自然驾驶统计一致性检验

Fig. 6 Naturalistic Statistical Consistency of the Following Tail Test Distribution

注：蓝色表示 EVT 尾部真实样本，橙色表示由尾部场景条件分布和条件扩散模型生成的样本； W_1 和 D_{KS} 分别为一维边缘分布的 Wasserstein-1 距离和 Kolmogorov-Smirnov 距离。

图 6 表明，跟驰场景的 Copula 采样和扩散解码没有破坏尾部跟驰的关键相互作用关系。初始间距、初始相对速度、前车速度变化和制动持续时间等场景条件边缘分布与经验尾部样本高度一致，其中初始间距和初始相对速度的 D_{KS} （Kolmogorov-Smirnov 距离，用于度量一维边缘分布差异）分别为 0.0077 和 0.0074，制动持续时间的 D_{KS} 为 0.0088。生成前车的初末速度、纵向位移和制动持续时间也与经验尾部轨迹接近，说明该分布能够把有限的尾部跟驰观测扩展为可重复采样的闭环扰动，同时保留车距压缩、相对速度和前车减速等风险形成变量。生成轨迹的加速度包络略宽、jerk 分布更分散，反映了平滑尾部条件下的动作泛化，而非对原始轨迹的逐条复刻。




图 7 切入尾部测试分布的自然驾驶统计一致性检验

Fig. 7 Naturalistic Statistical Consistency of the Cut-in Tail Test Distribution

注：蓝色表示 EVT 尾部真实样本，橙色表示由尾部场景条件分布和条件扩散模型生成的样本； W_1 和 D_{KS} 分别为二维边缘分布的 Wasserstein-1 距离和 Kolmogorov-Smirnov 距离。

图 7 显示，切入场景的尾部条件空间也得到较好覆盖：初始速度、初始横向偏移、初始相对速度、跨线时间和目标车速度变化等条件变量的 D_{KS} 多低于 0.052，目标车速度变化的 D_{KS} 为 0.0175。扩散生成轨迹保持了切入方向、横向位移和纵向位移的主要形态，车道进入率和进入后保持率分别为 1.000 和 1.000，而经验尾部样本为 0.972 和 0.922。与此同时，生成轨迹的平均跨线时间比经验尾部样本晚约 0.31 s，横向接近程度略强，说明切入语义约束提高了闭环测试中的有效切入比例，但也带来局部横向运动偏差。该结果支持将扩散先验作为自然驾驶尾部行为的平滑近似，并提示切入场景受尾部样本量较小和多模态横向运动影响，后续安全概率解释应限定在式 (11) 中 $X \sim \mathbb{P}_e$ 所对应的尾部测试分布下，而非全量自然驾驶分布下的无条件风险。

3.3 闭环安全关键概率的估计效率与暴露风险对比

闭环实验评估同一 IDM 策略，目标量为式 (11) 中的 $p_{ADS,e}$ ，即 $X \sim \mathbb{P}_e$ 时闭环风险达到 γ_e^* 的条件概率。独立 Monte Carlo 用作同一概率对象下的直接采样基线；子集模拟则在 $X = (o_e, z)$ 空间内逐层提高中间风险阈值，以更高频率访问安全关键域。估计得到的 $\hat{p}_{ADS,e}$ 按式 (13) 转换为单位里程风险强度，并与相同 EVT 阈值和全车辆里程分母下的 *highD* 自然驾驶暴露强度比较。直接 Monte Carlo 在跟驰和切入场景分别执行 100000 和 10000 次闭环评估；子集模拟的每层样本数 N 、中间事件条件概率 p_0 和潜变量扰动标准差 σ_p 分别设为 (3000, 0.2, 0.12) 和 (1000, 0.1, 0.10)。




图 8 子集模拟过程中风险样本向极值高风险区域的逐级迁移

Fig. 8 Progressive Migration of Risk Samples toward the EVT High-Risk Region during Subset Simulation

注：横轴为式 (10) 中的极值风险得分 $R_e(X)$ ；红色虚线为人类驾驶校准阈值 γ_e^* ，阴影区域表示安全关键域。

图 8 展示了子集模拟的风险得分迁移过程。跟驰场景中，得分 p90/p95 从第 0 层的 4.3884/4.8748 增至最终层的 6.6739/6.7119，失效比例由 0.00333 增至 0.31133；切入场景中，得分 p90/p95 从 1.6855/3.0838 增至 5.0421/6.2271，失效比例由 0.0070 增至 0.0680。跟驰最终层的主体分布已越过 γ_e^* ，切入最终层则表现为分布右尾越阈，说明切入安全关键域在其尾部测试分布中更加稀疏。总体而言，子集模拟在不改变目标概率对象的前提下，将闭环样本逐级推向人类驾驶校准的极值高风险区域。表 3 中 RSE（relative standard error，相对标准误差）用于衡量概率估计的相对不确定性。

表 3 闭环估计与 *highD* 自然暴露强度对比Table 3 Closed-loop estimates and naturalistic *highD* exposure intensities

场景	估计器	闭环次数	$\hat{p}_{\text{ADS},e}$	RSE	$\hat{\lambda}_{\text{ADS},e}/\text{km}$	$\lambda_{\text{HD},e}^*/\text{km}$	ADS 重现里程/km
跟驰	Monte Carlo	100000	0.0026	0.0625	4.327×10^{-4}	3.333×10^{-3}	2311.35 (7.70)
跟驰	子集模拟	29303	0.0025	0.0272	4.226×10^{-4}	3.333×10^{-3}	2366.41 (7.89)
切入	Monte Carlo	10000	0.0065	0.1236	5.831×10^{-5}	3.333×10^{-4}	17148.89 (5.72)
切入	子集模拟	3267	0.0068	0.1171	6.100×10^{-5}	3.333×10^{-4}	16392.32 (5.46)

注： $\lambda_{\text{HD},e}^*$ 为 *highD* 人类驾驶在同一 EVT 安全关键阈值下、按全车辆累计千米计算的暴露强度；括号内数值为 ADS 重现里程相对于 *highD* 人类驾驶重现里程的倍数。 $\hat{\lambda}_{\text{ADS},e}$ 由 $\hat{p}_{\text{ADS},e}$ 乘以同类尾部事件自然暴露强度换算，跟驰和切入尾部事件强度分别为 0.169666/km 和 0.008971/km。跟驰和切入直接 Monte Carlo 的 95% 置信区间分别为 [0.00224, 0.00286] 和 [0.00492, 0.00808]；子集模拟的 95% 近似置信区间分别为 [0.00236, 0.00262] 和 [0.00524, 0.00836]。

表 3 汇总了直接 Monte Carlo、子集模拟和 *highD* 自然暴露基线。在跟驰场景中，100000 次独立 Monte Carlo 得到 $\hat{p}_{\text{ADS},e} = 0.0026$ ，子集模拟用 29303 次闭环评估得到 0.0025，两者置信区间重叠，说明子集模拟没有改变目标概率解释；同时 RSE 从 0.0625 降至 0.0272。按独立 Monte Carlo 的 $N^{-1/2}$ 收敛关系估算，达到相近 RSE 约需 5.31×10^5 次独立闭环仿真，对应约 18.1 倍等精度加速。暴露映射后，IDM 在跟驰场景的安全关键风险强度为 $4.226 \times 10^{-4}/\text{km}$ ，为 *highD* 人类驾驶基线 $3.333 \times 10^{-3}/\text{km}$ 的 12.68%，对应重现里程 2366.41 km。

在切入场景中，直接 Monte Carlo 与子集模拟分别得到 0.0065 和 0.0068，仍保持同一概率对象下的一致性；子集模拟使用约 32.7% 的闭环评估次数达到相近 RSE，按同精度估算约实现 3.4 倍加速。暴露映射后，IDM 的安全关键风险强度为 $6.100 \times 10^{-5}/\text{km}$ ，为 *highD* 人类驾驶基线 $3.333 \times 10^{-4}/\text{km}$ 的 18.30%，对应重现里程 16392.32 km。跟驰最终层包含 190 个不同场景条件和 1961 个不同状态，切入最终层包含 222 个不同场景条件和 767 个不同状态，最大场景条件占比分别为 0.038 和 0.010，表明高风险样本未坍塌到少数条件或潜变量状态。

本小节结果表明，在本文设定的长尾风险空间内，被测 ADS 达到人类驾驶校准安全关

键阈值的暴露频率更低；同时，子集模拟在保持目标概率对象不变的前提下，以更少闭环仿真获得了与直接 Monte Carlo 一致的条件概率估计。

4 讨论与分析

当前实验以 *highD* 高速公路跟驰与切入场景为主要对象，所得风险阈值、尾部场景条件分布和单位暴露风险强度解释均受限于该数据集的道路类型、车辆类别和交互模式，后续应扩展到城市道路、匝道汇入、无保护转向和混合交通等更复杂 ODD。此外，本文以 IDM 策略作为被测 ADS 案例，主要验证方法框架的可行性，未来需要在学习型端到端驾驶策略、规划控制系统和真实工业级 ADS 上进一步检验其区分能力。未来也可进一步引入考虑 MCMC 相关性的方差估计、更多重现周期下的敏感性分析以及多数据集交叉验证，以增强长尾风险度量基准的稳健性和可信度。

5 结论

本文围绕自动驾驶长尾安全测试中风险阈值缺少自然驾驶参照、离线尾部事件难以闭环复现、稀有风险概率难以高效估计等问题，提出了一种基于自然驾驶先验与极值风险校准的长尾风险测试方法。该方法将自然驾驶数据从被动离线观测迁移为自动驾驶闭环评估的统计风险基准：通过极值理论标定人类驾驶尾部安全关键阈值，通过高斯 Copula 与条件扩散模型构建可采样、可复现且保持自然驾驶行为约束的尾部测试分布，并通过子集模拟估计被测 ADS 超过人类驾驶校准风险等级的条件概率。

实验结果表明，本文方法能够在跟驰与切入两类高速公路交互场景中形成场景自适应风险阈值，生成保持主要行为统计特征的尾部测试样本，并以少于直接 Monte Carlo 的闭环评估预算获得相近的稀有风险估计。由此，本文将长尾测试从“寻找危险样本”推进为“在自然驾驶统计参照下度量闭环风险”，为构建可解释、可比较且可概率化的自动驾驶长尾风险度量基准提供了方法路径。后续研究将面向更复杂运行设计域、更多类型被测驾驶策略和模型不确定性传播开展扩展，以提升该框架在真实自动驾驶系统测试中的稳健性和可信度。

参考文献

- [1] DYRO R, FOUTTER M, LI R, et al. Realistic Extreme Behavior Generation for Improved AV Testing[C/OL]//2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 1354-1362. <https://arxiv.org/abs/2409.10669>. DOI: 10.1109/ICRA55743.2025.11128450.
- [2] 蒋拯民, 党少博, 李慧云, 等. 自动驾驶汽车场景测试研究进展综述[J/OL]. 汽车技术, 2022(8): 10-22. DOI: 10.19620/j.cnki.1000-3703.20211088.
- [3] WANG J, PUN A, TU J, et al. AdvSim: Generating Safety-Critical Scenarios for Self-Driving Vehicles[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 9909-9918. DOI: 10.1109/CVPR46437.2021.00978.
- [4] HANSELMANN N, RENZ K, CHITTA K, et al. King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients[C/OL]//European Conference on Computer Vision. Springer, 2022: 335-352. DOI: 10.1007/978-3-031-19839-7_20.
- [5] FENG L, LI Q, PENG Z, et al. Trafficgen: Learning to generate diverse and realistic traffic

- scenarios[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3567-3575. DOI: [10.1109/ICRA48891.2023.10160296](https://doi.org/10.1109/ICRA48891.2023.10160296).
- [6] SUN S, GU Z, SUN T, et al. Drivescenegen: Generating diverse and realistic driving scenarios from scratch[J/OL]. IEEE Robotics and Automation Letters, 2024, 9(8): 7007-7014. DOI: [10.1109/LRA.2024.3416792](https://doi.org/10.1109/LRA.2024.3416792).
- [7] ZHONG Z, REMPE D, XU D, et al. Guided conditional diffusion for controllable traffic simulation[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3560-3566. DOI: [10.1109/ICRA48891.2023.10161463](https://doi.org/10.1109/ICRA48891.2023.10161463).
- [8] JIANG M, BAI Y, CORNMANN A, et al. Scenediffuser: Efficient and controllable driving simulation initialization and rollout[C/OL]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 55729-55760. DOI: [10.52202/079017-1771](https://doi.org/10.52202/079017-1771).
- [9] XIE Y, GUO X, WANG C, et al. AdvDiffuser: Generating Adversarial Safety-Critical Driving Scenarios via Guided Diffusion[C/OL]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2024: 9983-9989. DOI: [10.1109/IROS58592.2024.10802408](https://doi.org/10.1109/IROS58592.2024.10802408).
- [10] XU C, PETIUSHKO A, ZHAO D, et al. DiffScene: Diffusion-Based Safety-Critical Scenario Generation for Autonomous Vehicles[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(8): 8797-8805. DOI: [10.1609/aaai.v39i8.32951](https://doi.org/10.1609/aaai.v39i8.32951).
- [11] JIANG Z, LIU J, SUN P, et al. Generation of Risky Scenarios for Testing Automated Driving Visual Perception Based on Causal Analysis[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(11): 15991-16004. DOI: [10.1109/TITS.2024.3421343](https://doi.org/10.1109/TITS.2024.3421343).
- [12] 赵祥模, 赵玉钰, 景首才, 等. 面向自动驾驶测试的危险变道场景泛化生成[J/OL]. 自动化学报, 2023, 49(10): 2211-2223. DOI: [10.16383/j.aas.c220772](https://doi.org/10.16383/j.aas.c220772).
- [13] 朱宇, 徐志刚, 赵祥模, 等. 基于 TsGAN 的自动驾驶汽车高速公路变道切入测试场景自动生成算法[J/OL]. 华南理工大学学报 (自然科学版), 2024, 52(8): 76-88. DOI: [10.12141/j.issn.1000-565X.230229](https://doi.org/10.12141/j.issn.1000-565X.230229).
- [14] YAN X, ZOU Z, FENG S, et al. Learning naturalistic driving environment with statistical realism[J/OL]. Nature Communications, 2023, 14: 2037. DOI: [10.1038/s41467-023-37677-5](https://doi.org/10.1038/s41467-023-37677-5).
- [15] HAO K, CUI W, LUO Y, et al. Adversarial safety-critical scenario generation using naturalistic human driving priors[J/OL]. IEEE Transactions on Intelligent Vehicles, 2024, 9(9): 5392-5406. DOI: [10.1109/TIV.2023.3335862](https://doi.org/10.1109/TIV.2023.3335862).
- [16] REN K, YANG J, LU Q, et al. Intelligent testing environment generation for autonomous vehicles with implicit distributions of traffic behaviors[J/OL]. Transportation Research Part C: Emerging Technologies, 2025, 174: 105106. DOI: [10.1016/j.trc.2025.105106](https://doi.org/10.1016/j.trc.2025.105106).
- [17] FENG S, YAN X, SUN H, et al. Intelligent driving intelligence test for autonomous vehicles with naturalistic and adversarial environment[J/OL]. Nature Communications, 2021, 12: 748. DOI: [10.1038/s41467-021-21007-8](https://doi.org/10.1038/s41467-021-21007-8).
- [18] FENG S, SUN H, YAN X, et al. Dense reinforcement learning for safety validation of autonomous vehicles[J/OL]. Nature, 2023, 615: 620-627. DOI: [10.1038/s41586-023-05732-2](https://doi.org/10.1038/s41586-023-05732-2).

- [19] ZHANG S, JIANG Z, SANG M, et al. A Comprehensive Survey on Driving Compliance Assessment Methodologies for Autonomous Vehicles[J/OL]. IEEE Intelligent Transportation Systems Magazine, 2025, 17(4): 56-82. DOI: [10.1109/MITS.2025.3548869](https://doi.org/10.1109/MITS.2025.3548869).
- [20] ZHANG H, SUN J, TIAN Y. Accelerated safety testing for highly automated vehicles: Application and capability comparison of surrogate models[J/OL]. IEEE Transactions on Intelligent Vehicles, 2024, 9(1): 2409-2418. DOI: [10.1109/TIV.2023.3319158](https://doi.org/10.1109/TIV.2023.3319158).
- [21] KRAJEWSKI R, BOCK J, KLOEKER L, et al. The highD Dataset: A Drone Dataset of Naturalistic Vehicle Trajectories on German Highways for Validation of Highly Automated Driving Systems[C/OL]//2018 21st International Conference on Intelligent Transportation Systems (ITSC). 2018: 2118-2125. DOI: [10.1109/ITSC.2018.8569552](https://doi.org/10.1109/ITSC.2018.8569552).
- [22] JIANG Z, PAN W, LIU J, et al. Efficient and unbiased safety test for autonomous driving systems[J/OL]. IEEE Transactions on Intelligent Vehicles, 2023, 8(5): 3336-3348. DOI: [10.1109/TIV.2022.3213310](https://doi.org/10.1109/TIV.2022.3213310).
- [23] DAVISON A C, HUSER R. Statistics of Extremes[J/OL]. Annual Review of Statistics and Its Application, 2015, 2: 203-235. <https://www.annualreviews.org/content/journals/10.1146/annurev-statistics-010814-020133>.
- [24] ÅSLJUNG D, NILSSON J, FREDRIKSSON J. Using Extreme Value Theory for Vehicle Level Safety Validation and Implications for Autonomous Vehicles[J/OL]. IEEE Transactions on Intelligent Vehicles, 2017, 2(4): 288-297[2026-05-26]. <https://ieeexplore.ieee.org/abstract/document/8094027>. DOI: [10.1109/TIV.2017.2768219](https://doi.org/10.1109/TIV.2017.2768219).
- [25] AU S K, BECK J L. Estimation of small failure probabilities in high dimensions by subset simulation[J/OL]. Probabilistic Engineering Mechanics, 2001, 16(4): 263-277. DOI: [10.1016/S0266-8920\(01\)00019-4](https://doi.org/10.1016/S0266-8920(01)00019-4).
- [26] AU S K, PATELLI E. Rare event simulation in finite-infinite dimensional space[J/OL]. Reliability Engineering & System Safety, 2016, 148: 67-77. DOI: [10.1016/j.ress.2015.11.012](https://doi.org/10.1016/j.ress.2015.11.012).