

基于TsGAN的自动驾驶汽车高速公路变道切入 测试场景自动生成算法

朱宇¹ 徐志刚^{1†} 赵祥模¹ 王润民¹ 曲小波²

(1. 长安大学 车联网与智能汽车测试技术研究院, 陕西 西安 710018; 2. 清华大学 车辆与运载学院, 北京 100084)

摘要: 前方相邻车道车辆变道切入自动驾驶车辆所在车道是典型的高速公路自动驾驶高风险场景, 在实际高速公路上进行该类场景的复现测试存在非常高的安全风险, 虚拟仿真测试是解决该问题的最佳途径之一。为自动生成批量化的高保真高速公路变道切入测试场景, 该文提出了一种基于时间序列生成对抗网络(TsGAN)的自动驾驶汽车高速公路变道切入测试场景自动生成算法。该算法以变道切入时刻两车的车头时距和侧向时距为场景危险程度评价指标, 从高速公路真实轨迹数据集highD中提取4类不同危险程度的2853个变道切入场景实例, 基于TsGAN构建变道切入测试场景生成模型, 并利用所提取的真实轨迹数据训练模型; 其后, 采用所构建的模型生成前车变道轨迹和测试车变道切入时刻前的运行轨迹, 通过比较所生成的变道轨迹与真实轨迹之间的分布相似性、频谱误差, 验证所生成的轨迹的真实性。该文还分析了所生成的场景中变道切入时刻两车的运动关系及轨迹参数分布, 检验了自动生成的场景在自然场景中的覆盖度。结果显示: 从轨迹关键参数的分布来看, TsGAN模型生成的变道轨迹与真实轨迹的平均相似度达79.7%, 平均频谱误差小于8%, 落在最相似真实轨迹缓冲区的轨迹超过83.2%, 表明所生成的轨迹具有高真实性; 与所采集的真实场景相比, 所生成的场景实例覆盖范围更大, 在参数区间内分布更均匀, 变道切入时刻前方变道车辆与测试车的车头时距和侧向时距分别降低了17.83%和16.37%(平均值), 车辆轨迹参数分布区间平均增长了19.44%, 表明所生成的场景在自然场景中具有较高的覆盖度; 所提出的基于TsGAN的场景生成模型可模拟4种不同危险程度的变道切入测试场景, 具有较强的针对性。

关键词: 交通工程; 自动驾驶汽车; 变道切入; 虚拟测试场景; 生成对抗网络

中图分类号: U463.6

文章编号: 1000-565X(2024)08-0076-13

高速公路具有道路线形平顺、交通场景相对简单等特点, 是有可能最早实现自动驾驶汽车应用的

理想环境, 因此在高速公路场景下开展自动驾驶汽车的功能与性能测试成为了当前自动驾驶汽车理

收稿日期: 2023-04-11

基金项目: 陕西省杰出青年科学基金资助项目(2023-JC-JQ-45); 国家重点研发计划项目(2021YFB2501200); 国家自然科学基金重点资助项目(52232015); 陕西省重点研发计划项目(2021LLRH-04-01-03)

Foundation items: Supported by the Shaanxi Science Fund for Distinguished Young Scientists (2023-JC-JQ-45), the National Key Research and Development Program of China (2021YFB2501200), the Key Project of the National Natural Science Foundation of China (52232015) and the Key Research and Development Program of Shaanxi Province (2021LLRH-04-01-03)

作者简介: 朱宇(1989—), 男, 博士生, 助理研究员, 主要从事自动驾驶汽车测试研究。E-mail: yu.zhu@chd.edu.cn

通信作者: 徐志刚(1979—), 男, 博士, 教授, 博士生导师, 主要从事智能交通、车路协同、自动驾驶等研究。E-mail: xuzhigang@chd.edu.cn

论和技术研究领域的一个重要方向。变道切入作为在真实交通运行中出现频率较高且具有较高安全风险的驾驶行为，每年造成数万起交通事故，占我国交通事故总量的4.9%^[1-3]。**变道切入场景已成为自动驾驶汽车测试的重要场景之一**^[4]。

相比实际道路测试，自动驾驶汽车虚拟仿真测试通过构建一系列接近真实交通场景的测试场景，实现虚拟环境中的自动驾驶汽车运行能力验证，具有测试安全性好、测试场景灵活性强、场景构建成本低等优点^[4-8]，是执行变道切入等具有较高安全风险的测试场景的优先选择。其中，测试场景构建是虚拟仿真测试的关键，研究者们常采用基于真实交通数据的虚拟测试场景生成方法来保证测试场景的真实性与有效性^[9]。真实交通数据通常来源于交通事故数据^[10]、自然驾驶数据^[11-12]、数据采集车传感器数据^[13]、路侧设备采集数据^[14-17]和航拍数据^[18-21]。由于真实交通数据中包含的安全场景较多，高风险场景较少，直接利用真实交通数据构建测试场景存在高风险场景数量不足的问题，不利于开展自动驾驶汽车的虚拟强化测试，因此需要通过场景生成来增加高风险场景的数量。

早期测试场景生成研究中，人们主要关注变道切入时刻两车的运动关系。文献[22-24]以变道过程中两车的距离、速度差和碰撞时间为参数建立变道模型，利用蒙特卡洛方法随机生成测试场景，但未获得变道切入场景中车辆的运动轨迹。Rocklage等^[25]通过建立变道轨迹网格模型来生成变道轨迹，但没有考虑生成的变道轨迹是否满足真实环境中的车辆动力学约束，是否接近真实驾驶人操纵下的车辆轨迹特征。Yao等^[26]建立了五阶多项式变道轨迹模型，通过优化搜索来保证所生成的变道轨迹与真实变道轨迹的相似性。Xu等^[27]和Wang等^[28]模拟了真实驾驶人的驾驶行为，通过建立动态变道模型来生成变道轨迹。Krajewski等^[29]将变道轨迹视为受参数影响的图线，通过建立基于互信息生成对抗网络和自编码器的轨迹生成模型来生成变道轨迹。

以上方法均未考虑车辆位置随时间变化的条件分布特性。在时间条件分布特性方面，目前研究者们大多聚焦于对轨迹自回归模型的改进，研究成果通常应用于车辆轨迹规划和预测中^[30-31]，较少生成完整的运动轨迹。针对这一问题，朱宇等^[32]提出了基于蒙特卡洛模拟(Monte Carlo Simulation, MCS)的轨迹生成算法，利用马尔科夫链模拟轨迹中车辆

位置的时间条件分布，同时，在条件分布约束下，基于真实轨迹数据建立每个离散时刻车辆的位置分布模型，通过蒙特卡洛模拟获得完整的车辆运动轨迹。针对变道切入场景，该方法分别设计了变道轨迹模型、测试车运动轨迹模型和变道切入时刻两车运动关系模型，但这3个模型间彼此独立，未考虑两车轨迹和变道点处两车运动关系的影响。

针对上述问题，本文试图提出一种基于时间序列生成对抗网络(TsGAN)的变道切入测试场景自动生成算法，以期利用TsGAN适合用来生成时间相关的序列数据、能捕捉每个时间点处的多维变量特征分布以及变量跨越时间的潜在动态变化^[33]的特性，实现变道切入测试场景中变道轨迹、测试车轨迹和变道切入时刻两车间运动关系的同时生成。

1 变道切入场景分析

为验证自动驾驶汽车应对其他车辆变道切入时控制算法的安全性及可靠性，在变道切入场景分析中将真实的高速直线道路变道切入场景简化为两车之间的典型变道切入场景。如图1所示，车辆C为变道车，车辆F在真实场景中为跟随车，在测试场景中则为所测试的自动驾驶汽车。




图1 典型变道切入场景模型

Fig. 1 Model of typical lane-change cut-in scenario

根据两车运动轨迹，将变道切入场景分为变道起始阶段、变道切入时刻和变道结束阶段^[32]。在变道起始阶段，车辆C沿车道2行驶，车辆F沿车道1行驶。以车辆C加速度 $a_c(t)$ 在 y 方向分量 $a_{cy}(t)$ 最大的时刻($a_{cy}(t) > 0$)为变道场景起点时刻 t_s ，则车辆C的轨迹起点为 $(x_c(t_s), y_c(t_s))$ ，车辆F的轨迹起点为 $(x_f(t_s), y_f(t_s))$ 。在变道切入时刻 t_c ，车辆C进入车道1，轨迹斜率为 $k(t_c)$ 。以 t_c 时刻车辆C的位置为轨迹坐标零点。若两车存在碰撞危险，车辆F应执行减速制动，避免与车辆C发生碰撞^[34]。在变道结束

阶段, 以 $|a_{Cy}(t)|$ 最大时刻 ($a_{Cy}(t) < 0$) 为变道场景终点时刻 t_e , 则车辆 C 和车辆 F 的轨迹终点分别为 $(x_C(t_e), y_C(t_e))$ 和 $(x_F(t_e), y_F(t_e))$ 。两车运动轨迹的关键参数如表 1 所示。

表 1 轨迹的关键参数

Table 1 Key parameters of trajectories

场景变化过程	轨迹参数	描述
变道起始阶段	$(x_C(t_s), y_C(t_s))$	车辆 C 的轨迹起点
	$(x_F(t_s), y_F(t_s))$	车辆 F 的轨迹起点
	r_s	变道起始阶段车辆 C 的轨迹特征参数
变道切入时刻	$k(t_c)$	变道切入时刻车辆 C 的轨迹斜率
变道结束阶段	$(x_C(t_e), y_C(t_e))$	车辆的 C 的轨迹终点
	$(x_F(t_e), y_F(t_e))$	车辆 F 的轨迹终点
	r_e	变道结束阶段车辆 C 的轨迹特征参数

轨迹特征参数 r_s 和 r_e 表征变道轨迹的形态特征。如图 2 所示, r_s 为车辆 C 接近变道切入时刻位置的轨迹长度 l_1 与变道起始阶段车辆 C 轨迹长度 l_s 的比值, r_e 为车辆 C 远离变道切入时刻位置的轨迹长度 l_2 与变道结束阶段车辆 C 轨迹长度 l_e 的比值, 即

$$r_s = l_1 / l_s \quad (1)$$

$$r_e = l_2 / l_e \quad (2)$$




图 2 变道轨迹的形态特征示例

Fig. 2 Example of morphological characteristics of lane-change trajectory

利用变道切入时刻两车的运动关系来评价变道切入场景的危险程度^[32], 通常选择两车碰撞时间 (TTC, 以 t_{TC} 表示) 或两车车头时距 (THW, 以 t_{HW} 表示) 作为评价指标^[11, 35-37]。通过分析真实场景数据发现, TTC 的分布范围较大且存在负值, 采用 TTC 作

为真实变道场景危险程度评价指标可能导致分析范围缩小, 不利于真实场景分析^[38], 故本文采用 THW 作为变道切入场景危险程度评价指标^[39-40], 即有

$$t_{HW} = D / v_{Fx}(t_c) \quad (3)$$

式中, D 为变道切入时刻 (t_c) 两车在 x 方向的距离, $v_{Fx}(t_c)$ 为车辆 F 在 t_c 时刻的 x 方向速度。

在变道切入场景中, 两车纵向间距对驾驶人感知的危险程度同样存在一定的影响^[38]。因此, 采用变道时刻两车侧向时距 (LTG, 以 t_{LG} 表示) 来表征变道切入过程中两车纵向间距对场景危险程度的影响,

$$t_{TG} = G / v_{Cy}(t_c) \quad (4)$$

式中, G 为变道切入时刻两车在 y 方向的距离, $v_{Cy}(t_c)$ 为车辆 C 在 t_c 时刻的 y 方向速度。车辆 C 和车辆 F 在 t_c 时刻的位置分别为 $(x_C(t_c), y_C(t_c))$ 和 $(x_F(t_c), y_F(t_c))$, 在 t_c 时刻的速度分别为 $v_C(t_c) = (v_{Cx}(t_c), v_{Cy}(t_c))$ 和 $v_F(t_c) = (v_{Fx}(t_c), v_{Fy}(t_c))$,

$$D = x_C(t_c) - x_F(t_c) \quad (5)$$

$$G = y_C(t_c) - y_F(t_c) \quad (6)$$

2 基于 TsGAN 的测试场景生成


2.1 真实场景数据提取

将四轴无人机采集的 highD 数据集^[18]作为高速公路真实变道切入场景数据来源。根据场景分析结果, 以 t_{HW} 和 t_{LG} 作为场景危险程度评价指标, 提取真实场景中具有中高风险的真实场景 2 853 个, 并将其危险程度划分为 4 类, 如图 3 所示。


在真实变道切入场景中, 变道起始时刻与结束时刻间持续时间在 4 s 以内的场景实例占 90% 以上。因此, 针对每个真实场景实例, 提取变道切入时刻前后共计 8 s 内的 201 个轨迹数据点组成真实场景数据集。若所提取轨迹中的数据量不足, 则依据轨迹变化趋势补足 201 个数据点。

真实场景数据集中的车辆轨迹数据包含各时刻两车的位置 $(x(t), y(t))$ 、速度 $(v_x(t), v_y(t))$ 和加速度 $(a_x(t), a_y(t))$ 。当采样间隔很小时, 速度和加速度可由相邻时刻的位置计算获得^[32]。因此, 以两车轨迹位置序列 $\{X_C(t), Y_C(t), X_F(t), Y_F(t)\}$ 作为测试场景生成模型训练数据。为训练模型对逐步条件分布的捕捉能力, 设定生成模型输入序列长度为 101 帧, 对训练数据中长度为 201 帧的轨迹序列, 从轨迹起点开始以步长 1 进行滑动分割, 将单一真实轨迹序


列进一步扩展为一组包含101个对应时刻轨迹的训练轨迹序列集。




(a) 分类1: 高风险($t_{HW} \in (0.0, 0.6]$ s, $t_{LG} \in (0.0, 0.3]$ s)



(b) 分类2: 较高风险($t_{HW} \in (0.6, 1.1]$ s, $t_{LG} \in (0.0, 0.3]$ s)



(c) 分类3: 较高风险($t_{HW} \in (0.0, 0.6]$ s, $t_{LG} \in (0.3, 0.6]$ s)



(d) 分类4: 中风险($t_{HW} \in (0.6, 1.1]$ s, $t_{LG} \in (0.3, 0.6]$ s)

图3 所提取的真实变道切入场景的分类

Fig. 3 Classification of extracted real lane-change cut-in scenarios

2.2 测试场景生成模型

真实变道切入场景中, 两车的运动轨迹是时间延续的随机过程 $W(\theta, t)$ (其中: $t \in T$, T 为时间; θ 为轨迹的位置参数), 样本空间 $\Theta = \{\theta\}$, 服从车辆轨迹分布 P 。由于轨迹序列中 T 为离散集, 若关注总时长为 T_s 的变道切入场景, 则两车运动轨迹序列可表示为 $W_{1:T_s}$ 。在任意时刻 t , 两车运动状态可表示为 W_t , $t \in \{t_1, t_2, \dots, T_s\}$ 。若模型生成的测试场景中两车的运动轨迹为 $\hat{W}_{1:T_s}$, 服从分布 $\hat{P}(\hat{W}_{1:T_s})$, 则模型生成场景中的车辆轨迹分布 $\hat{P}(\hat{W}_{1:T_s})$ 应尽可能近似于真实场景中的轨迹分布 $P(W_{1:T_s})$, 即对于参数为 φ ($\varphi \in \Phi$, Φ 为模型参数空间) 的测试场景生成模型 $m(\varphi)$, 满足

$$D(\hat{P}(\hat{W}_{1:T_s}) \| P(W_{1:T_s})) = \min_{m(\varphi), \varphi \in \Phi} D(\hat{P}(\hat{W}_{1:T_s}) \| P(W_{1:T_s})) \quad (7)$$


式中, $D(*)$ 为不同分布间距离的度量。

与传统生成对抗网络不同, TsGAN 关注车辆运动轨迹 $W_{1:T_s}$ 中 t 时刻的两车运动状态 W_t 与该时刻前两车轨迹 $W_{1:t-1}$ 间的条件分布 $P(W_t | W_{1:t-1})$, 即对于联合分布 $P(W_{1:T_s})$, 存在逐步条件分布 $P(W_t | W_{1:t-1})$ ($t \in \{t_1, t_2, \dots, T_s\}$), 使得 $P(W_{1:T_s}) = \prod_t P(W_t | W_{1:t-1})$ 。因此, 基于 TsGAN 的生成场景中车辆轨迹的逐步条件分布 $\hat{P}(\hat{W}_t | \hat{W}_{1:t-1})$ 应接近真实的逐步条件分布 $P(W_t | W_{1:t-1})$ 。对于任意时刻 t ($t \in \{t_1, t_2, \dots, T_s\}$), 要求场景生成模型 $m(\varphi)$ 满足

$$D(\hat{P}(\hat{W}_t | \hat{W}_{1:t-1}) \| P(W_t | W_{1:t-1})) = \min_{m(\varphi), \varphi \in \Phi} D(\hat{P}(\hat{W}_t | \hat{W}_{1:t-1}) \| P(W_t | W_{1:t-1})) \quad (8)$$

为使模型能够捕捉真实轨迹中的逐步条件分布, 测试场景生成模型保留了 TsGAN 中的隐编码空间及对应的编码器、解码器, 以保证模型对轨迹数据动态特性的学习能力, 同时忽略 TsGAN 中对数据静态特征的学习过程。模型的基本结构如图4所示, 各模块通过多级门控循环单元(GRU)构建。

隐编码空间 $\mathcal{H}$ 描述了数据的潜在时间动态特性。测试场景生成模型中, 编码器提供轨迹潜在时间动态特性 $\mathcal{W}$ 与隐编码空间 $\mathcal{H}$ 之间的映射 $e: \prod_t \mathcal{W} \rightarrow \prod_t \mathcal{H}$ 。真实轨迹序列 $W_{1:T_s}$ 通过编码器获



G_{uloss} 、 G_{class} 和 G_{loss} 分别为对抗损失、重建损失和监督损失, E_{loss} 为编解码损失函数, S_{loss} 为生成器监督损失函数, D_{loss} 为判别器损失函数, $\hat{V}$ 为生成轨迹判别结果, V 为真实轨迹判别结果, $\tilde{W}_{1:T_s}$ 为还原轨迹序列, $\hat{V}_e$ 为生成器初级生成轨迹序列的判别结果, $\hat{E}_{1:T_s}$ 为生成器初级生成轨迹序列的隐编码, $H_{1:T_s-1}$ 为在 $t \in \{t_1, t_2, \dots, T_{s-1}\}$ 时刻的真实轨迹隐编码, $\bar{H}_{2:T_s}$ 为真实轨迹的监督序列

图 4 基于TsGAN的测试场景生成模型的基本结构

Fig. 4 Basic structure of the test scenario generation model based on TsGAN

得隐编码 $H_{1:T_s} (H_{1:T_s} = e(W_{1:T_s}))$, 实现轨迹潜在时间动态特性在隐编码空间的降维表征^[33]。对于具有逐步条件分布的轨迹数据, 其在任意时刻 t 的隐编码状态 $h_t = e(h_{t-1}, w_t)$ 。解码器将隐编码 $H_{1:T_s}$ 解码为还原序列 $\tilde{W}_{1:T_s}$, 完成隐编码空间 $\mathcal{H}$ 与轨迹潜在时间动态特性 $\mathcal{W}$ 的逆映射 $r: \prod_t \mathcal{H} \rightarrow \prod_t \mathcal{W}$ 。

模型的判别器和生成器同样运行在隐编码空间中。判别器执行隐编码序列的判别函数 $d: \prod_t \mathcal{H} \rightarrow [0, 1]$, 返回对真实轨迹隐编码与所生成轨迹隐编码的分类结果。生成器输入随机动态序列 $Z_{1:T_s}$, 以获得接近真实轨迹隐编码的生成轨迹隐编码 $\hat{H}_{1:T_s}$, $\hat{H}_{1:T_s} = g(Z_{1:T_s})$ 。模型的生成器采用二级结构, 其中初级结构实现随机动态序列 $Z_{1:T_s}$ 的编码, 生成隐编码中的逐步条件分布 $\hat{P}(H_t|H_{1:t-1})$; 次级结构逼近真实条件分布 $P(H_t|H_{1:t-1})$, 既保证了模型捕获真实轨迹的逐步条件分布特性, 又有利于模型训练。

2.3 测试场景生成

测试场景生成分为模型初始化阶段、模型训练阶段和测试场景轨迹生成阶段。在模型初始化阶段, 根据表 2 所示的参数初始化测试场景生成模型, 建立 4 种不同危险程度的真实场景对应的训练轨迹序列集。模型训练阶段包括编码器与解码器预训练、生成器预训练及模型联合训练。

表 2 测试场景生成模型的参数设置

Table 2 Parameter settings of test scenario generation model

模型参数	取值
输入训练轨迹/随机序列长度	101
批次大小 (Batchsize)	256
编码器学习率	0.0035
解码器学习率	0.005
生成器学习率	0.01
判别器学习率	0.005
编码器与解码器预训练次数	100
生成器预训练次数	50
最大联合训练次数	3000

2.3.1 编码器与解码器预训练

编解码器提供真实轨迹序列与隐空间的映射, 是执行生成器和判别器训练的前提。预训练过程如图 4 中虚线箭头所示, 真实轨迹序列 $W_{1:T_s}$ 输入编码器获得隐编码 $H_{1:T_s}$, 再解码为还原序列 $\tilde{W}_{1:T_s}$, 通过计算损失函数 E_{loss} 训练真实轨迹序列潜在的动态特征和隐编码之间的可逆映射, 即

$$E_{loss} = E_{W_{1:T_s} \sim P} \left[\sum_t \|w_t - \tilde{w}_t\|_2 \right] \quad (9)$$

式中, w_t 和 $\tilde{w}_t$ 分别为 t 时刻的真实轨迹状态和生成轨迹状态。

2.3.2 生成器预训练

为训练模型, 使其能够捕捉真实轨迹序列的逐

步条件分布,引入监督学习方法对生成器进行预训练。如图4中点划线箭头所示,真实轨迹序列经编码器获得隐编码 $H_{1:T_s}$,再输入生成器,经次级计算输出编码 $\bar{H}_{1:T_s}$ 。通过计算真实轨迹编码与输出编码的损失函数 S_{loss} ,优化生成器捕捉真实轨迹序列逐步条件分布的能力,

$$S_{\text{loss}} = E_{H_{1:T_s} \sim P} \left[\sum_t \|h_t - \bar{h}_t\|_2 \right] \quad (10)$$

式中, h_t 为 t 时刻的隐编码状态, $\bar{h}_t$ 为 t 时刻监督序列的隐编码状态。

2.3.3 模型联合训练

模型联合训练引入对抗损失 G_{uloss} 、重建损失 G_{eloss} 和监督损失 G_{sloss} 同时训练编解码器及生成器、判别器。如图4中实线箭头所示,将所生成的轨迹的隐编码 $\hat{H}_{1:T_s}$ 与真实轨迹的隐编码 $H_{1:T_s}$ 分别输入判别器,计算判别结果 $\hat{V}$ 和 V ,共同计算对抗损失 G_{uloss} ,实现生成器与编码器的迭代优化,

$$G_{\text{uloss}} = E_{W_{1:T_s} \sim P} \left[\sum_t \log v_t \right] + E_{W_{1:T_s} \sim \hat{P}} \left[\sum_t \log (1 - \hat{v}_t) \right] \quad (11)$$

与预训练相似,联合训练通过计算真实轨迹序列 $W_{1:T_s}$ 与编解码结果 $\hat{W}_{1:T_s}$ 的重建损失 G_{eloss} ,训练轨迹序列潜在的时间动态特征和隐编码之间的可逆映射。同时,联合训练将真实轨迹序列的隐编码输入经对抗优化后的生成器中,通过监督损失 G_{sloss} 进一步训练场景生成模型对逐步条件分布的捕捉能力,

$$G_{\text{eloss}} = E_{W_{1:T_s} \sim P} \left[\sum_t \|w_t - \tilde{w}_t\|_2 \right] \quad (12)$$

$$G_{\text{sloss}} = E_{W_{1:T_s} \sim P} \left[\sum_t \|h_t - g(h_{t-1}, z_t)\|_2 \right] \quad (13)$$

式中, z_t 为 t 时刻的随机序列状态, $g(h_{t-1}, z_t)$ 为生成器生成的 t 时刻的隐编码状态。

在测试场景轨迹生成阶段,模型输入随机序列 $Z_{1:T_s}$,经生成器获得隐编码,最终通过解码器生成变道切入场景中车辆C和车辆F的轨迹 $\tilde{W}_{1:T_s} = \{\tilde{X}_C(t), \tilde{Y}_C(t), \tilde{X}_F(t), \tilde{Y}_F(t)\}$ 。

3 结果验证与分析

本节将从真实性和覆盖度两方面对测试场景生成结果进行分析和验证,并与基于蒙特卡洛模拟的测试场景生成结果进行对比。此外,将生成的测试场景导入PreScan虚拟测试平台,执行生成场景中的自动驾驶测试。

3.1 真实性

在真实变道切入场景中,车辆运动轨迹由车辆动力学和驾驶人的控制策略综合决定。为保证所生成的测试场景中的车辆轨迹依然符合真实车辆动力学约束条件和真实驾驶人控制策略,生成的轨迹需与真实轨迹具有较高的相似性。本文分别从时域和频域分析真实轨迹和所生成轨迹的相似性。时域中以变道轨迹的关键参数分布为对象,通过海林格距离(HD,以 d_H 表示)和平均绝对误差(MAE,以 e_{ma} 表示)进行相似性量化。同时采用基于MCS算法的变道轨迹生成结果作为对比^[32]。HD和MAE分别反映两种概率分布的整体相似性和 n 个区间中每一个对应区间的平均相似程度,在 $[0, 1]$ 范围内取值,其值越小表明两种分布的相似度越高^[41],

$$d_H(P, Q) = \frac{1}{\sqrt{2}} \left\| \sqrt{P} - \sqrt{Q} \right\|_2 \quad (14)$$

$$e_{\text{ma}}(P, Q) = \frac{1}{n} \sum_i |p_i - q_i| \quad (15)$$

式中, P 和 Q 为两种不同方法生成的轨迹的分布, p_i 和 q_i 为第 i 个区间中两种不同方法生成的轨迹的分布。

两种算法生成的轨迹的平均相似度 S_a 、轨迹关键参数在各对应区间的差异度 D_a 和轨迹所有关键参数的平均差异度 $\bar{D}_a$ 可定义为

$$S_a = \left(\sum_m (1 - d_H) / m \right) \times 100\% \quad (16)$$

$$D_a = e_{\text{ma}} \times 100\% \quad (17)$$

$$\bar{D}_a = \left(\sum e_{\text{ma}} / m \right) \times 100\% \quad (18)$$

式中, m 为轨迹关键参数的数量。

如表3所示,从轨迹关键参数分布的整体相似性来看,TsGAN模型生成的变道轨迹与真实轨迹的相似度较高,两者的平均相似度达79.7%,超过MCS算法的平均相似度74.1%。TsGAN模型生成的

表3 轨迹关键参数的相似性

Table 3 Similarity of critical trajectory parameters

轨迹参数	HD		MAE	
	TsGAN模型	MCS算法	TsGAN模型	MCS算法
$(x_c(t_s), y_c(t_s))$	0.213	0.227	0.0130	0.033
r_s	0.232	0.266	0.0200	0.030
$k(t_c)$	0.182	0.237	0.0058	0.011
$(x_c(t_e), y_c(t_e))$	0.175	0.212	0.0085	0.030
r_e	0.215	0.351	0.0140	0.047

变道轨迹的 5 项参数的分布相似度均优于 MCS 算法结果,其中最明显的是变道切入时刻车辆 C 的轨迹斜率 $k(t_c)$ 及变道轨迹形态特征参数 r_s 、 r_e 的相似度。

对于轨迹关键参数在各对应区间的平均差异度, TsGAN 模型生成的轨迹与真实轨迹的差异也较小,平均相差 1.23%, 小于 MCS 算法的平均差距 3.02%。其中 TsGAN 模型在变道切入时刻的轨迹斜率 $k(t_c)$ 与真实轨迹仅相差 0.58%, 具有较高的真实性。

为从生成场景中筛选出与真实轨迹具有较好相似性的轨迹, 引入如图 5 所示的真实轨迹缓冲区^[32], 以所生成轨迹 K_g 与其最相似真实轨迹 $\tilde{K}_r$ 的平均弗雷歇距离为缓冲区宽度。




图 5 真实变道轨迹缓冲区示例

Fig. 5 Example of real lane-change trajectory buffer

对于所生成的轨迹 $K_g = \{u_{a_1}, \dots, u_{a_p}\}$ 与其最相似真实轨迹 $\tilde{K}_r = \{v_{b_1}, \dots, v_{b_p}\}$ 中的对应点对序列 $\{(u_{a_1}, v_{b_1}), \dots, (u_{a_i}, v_{b_i}), \dots, (u_{a_p}, v_{b_p})\}$, 令 $a_{i+1} = a_i$ 或 $a_{i+1} = a_i + 1$, $b_{i+1} = b_i$ 或 $b_{i+1} = b_i + 1$, 则弗雷歇距离 L_F 为

$$L_F = \inf_{i=1, \dots, p} \max d(u_{a_i}, v_{b_i}) \quad (19)$$

在 TsGAN 模型生成的 6000 组变道切入场景中, 所生成的变道轨迹与其最相似真实轨迹的平均弗雷歇距离为 0.11 m, 相比 MCS 算法减小了 0.01 m^[32]。所生成的变道轨迹中, 超过 83.2% 的落在最相似真实轨迹缓冲区内, 这进一步证明了生成轨迹的真实性。同时, 通过对溢出缓冲区的轨迹予以剔除, 既可以获得不存在于真实数据集中的轨迹, 又可以保证所生成的轨迹满足车辆动力学和真实驾驶人操纵特征的约束, 具备良好的场景有效性。

为确认 TsGAN 模型能否捕捉到真实场景中车辆轨迹的动态变化, 对生成的变道轨迹进行频域分

析。如式(20)所示, 计算所生成的轨迹与真实轨迹的平均频谱误差 Z , 验证频谱的整体相似性。搜索生成的每组变道轨迹的最相似真实轨迹, 并通过式(21)计算所生成的轨迹与最相似真实轨迹的平均频谱误差 z_i , 分析每条生成轨迹与真实轨迹的相似性^[42]。

$$Z = \sum_l \left(\sqrt{\left(\frac{\sum_i F_{i,l}}{N} - \frac{\sum_j f_{j,l}}{n} \right)^2} \right) \quad (20)$$

$$z_i = \sum_l \left(\sqrt{\left(F_i - f_s^i \right)^2} \right) / N \quad (21)$$

式中, F 为所生成的变道轨迹的频谱, f 为真实变道轨迹的频谱, f_s^i 为与所生成的变道轨迹 i 最相似的真实轨迹的频谱, i 和 j 分别为所生成的变道轨迹和真实变道轨迹的序号, l 为轨迹离散频谱中的取值点序号, N 为所生成的轨迹的数量, n 为真实轨迹的数量, L 为离散频谱取值点的数量。

如表 4 所示, 生成的变道轨迹在 x 、 y 方向的频谱 F_x 、 F_y 与真实轨迹的平均频谱误差均小于 8%, 表明轨迹生成模型能够捕捉到真实场景中车辆轨迹的动态变化, 所生成的轨迹与真实轨迹具有较好的相似性。采用两种方法生成的轨迹的平均误差相近, 其中 TsGAN 模型生成的变道轨迹的平均频谱误差更小, 真实性更优。同时, TsGAN 模型生成的轨迹与其最相似真实轨迹的平均频谱误差小于 6.5%, 比 MCS 算法生成的轨迹的相似度更高, 表明 TsGAN 模型能够获得真实性更优的生成场景。

表 4 变道轨迹频谱的相似性

Table 4 Similarity of trajectory frequency spectrum

参数	$Z/\%$		$z_i/\%$	
	TsGAN 模型	MCS 算法	TsGAN 模型	MCS 算法
F_x	7.54	7.82	6.46	6.93
F_y	4.45	4.79	3.15	3.57

3.2 覆盖度

为验证场景生成对场景覆盖度的提升效果, 首先考虑变道切入时刻两车的运动关系。以高风险场景为例, 如图 6 所示, 图中每个点表示一组场景实例中变道切入时刻两车的纵横向运动关系。对场景实例的分布进行聚类分析并绘制概率分布的等高线图, 可以发现, 相比所采集的真实场景, 生成的场景实例在参数区间内分布更加均匀, 且包含大量在所采集的真实数据中不存在的场景。

引入 Ripley's K 函数分析场景实例点的分布。




图6 变道切入时刻两车的运动关系

Fig. 6 Movement relationship between two vehicles at the lane-change cut-in moment

如式(22)所示, Rispely's K 函数假设在参数区间内放置一系列半径为 d 的圆, 圆心依次放在每个实例点上, 计算每个圆内的实例点数量, 遍历所有实例点后计算平均值。将平均值除以参数区间内的实例点密度, 获得距离为 d 时的 Rispely's K 函数值 $K(d)^{[43-44]}$, 计算式如下:


$$K(d) = \frac{A}{n^2} \sum_{i \neq j} I_d(d_{ij}) \quad (22)$$

式中: A 为参数区间的面积; n 为参数区间内场景实例点的数量; d_{ij} 为实例点之间的距离; I_d 表征实例点是否在半径为 d 的圆内, 且

$$I_d(d_{ij}) = \begin{cases} 1, & d_{ij} \leq d \\ 0, & d_{ij} > d \end{cases} \quad (23)$$

选择半径 d 的取值范围为 $(0.0, 0.3]$ s, 分别计算不同半径下TsGAN模型生成场景实例点分布的 Rispely's K 函数值, 形成图7所示的 Rispely's K 函数曲线。作为对比, 图7中还列出了相同条件下真实场景实例点、MCS算法生成场景实例点和参数取值范围内均匀分布实例点的 Rispely's K 函数曲线。

由图7可见, 在相同的 t_{HW} 和 t_{LG} 取值范围内,

图7 变道切入场景实例点分布的 Rispely's K 函数曲线Fig. 7 Rispely's K function curves of the distribution of lane-change cut-in scenario instance points

均匀分布实例点的聚集程度最低。当 d 取值较小时, 真实场景实例点的分布相比TsGAN模型生成场景实例点的更分散; 当 d 取值较大时, TsGAN模型生成场景实例点的分布比真实场景实例点的更分散。结合图6可知: 大部分真实场景实例点分布在场景参数取值范围内的部分区域, 分布在其他区域中的数量较少; TsGAN模型生成场景实例点在参数取值范围内的整体分布较为均匀, 但是在小区域内的分布较真实场景实例点的更为集中。相比MCS算法, TsGAN模型生成场景实例点的分布均匀性更好。

以上分析表明, 对于变道切入时刻两车的运动关系, 相比所提取的真实场景实例, TsGAN模型生成的场景实例覆盖范围更大, 在参数区间内的整体分布更加均匀。而且, 通过测试场景的生成可以获得更多真实数据中不存在的场景, 有效提升场景覆盖范围。此外, 通过计算可知, 所生成的场景的 t_{HW} 和 t_{LG} 值相比真实场景的分别降低了17.83%和16.37%(平均值), 说明在相同危险程度分类下TsGAN模型能够生成比真实场景危险程度更高的测试场景。

分别计算所生成场景与真实场景中关键轨迹参数的分布区间, 得到表5所示的所生成场景轨迹参数的分布区间增长比例。可以发现, 相比真实场景轨迹参数, 所生成场景的轨迹参数区间均有不同程度的增长, 最大增长89.79%, 平均增长19.44%, 表明通过生成测试场景可以增大轨迹分布的区间, 获得真实数据中不存在的两车运动轨迹, 提升轨迹的多样性和覆盖度。

表 5 所生成场景的轨迹参数区间增长比例


Table 5 Interval increasing ratios of trajectory parameters of the generated scenario

轨迹参数	参数区间增长比例/%	轨迹参数	参数区间增长比例/%
$x_c(t_s)$	5.72	$x_c(t_e)$	16.80
$y_c(t_s)$	23.73	$y_c(t_e)$	3.16
$x_f(t_s)$	6.00	$x_f(t_e)$	22.96
$y_f(t_s)$	3.57	$y_f(t_e)$	89.79
r_s	6.57	r_e	29.93
$k(t_e)$	5.56		


3.3 所生成场景的验证测试

利用所提出的场景自动生成算法,可同时获得车辆C和车辆F在4类不同危险程度的测试场景中的运动轨迹。针对不同测试需求,通过在PreScan仿真平台中搭建虚拟测试场景,并导入所生成的测试场景中的车辆运动轨迹,可以验证前车变道切入场景下自动驾驶汽车响应控制算法的有效性。

图8为不同危险程度测试场景下的自动紧急制动虚拟测试结果示例,图9给出了其中高风险场景实例的PreScan虚拟测试过程快照。在初始状态下,车辆F以32.3 m/s的速度接近车辆C;在 t_1 时刻,车



(a) 车辆F的x方向速度



(b) 两车的x方向距离

图8 虚拟测试结果

Fig. 8 Results of virtual testing




图9 高风险场景实例的虚拟测试过程快照

Fig. 9 Snapshots of virtual testing process in high-risk scenario

辆F发现车辆C有变道意图;在车辆C的变道过程中,车辆F速度逐渐降低;车辆C变道进入车辆F行驶车道后,在 t_2 时刻车辆F发现与车辆C存在碰撞风险,及时减速制动避免与车辆C发生碰撞;在 t_3 时刻,两车距离最近;最终车辆F跟随车辆C行驶,速度与车辆C接近。对比图8中不同危险程度场景中的测试结果可知,高风险场景中车辆F最早执行制动减速,中风险场景中车辆F最晚执行制动减速,两类较高风险场景中车辆F的制动执行时刻相近,但 t_{LC} 较小的测试场景中的制动时刻较早,表明在变道切入时刻,两车距离越近则车辆F认为安全风险越高,自动紧急制动介入就越早。

4 结语

本文提出了一种基于时间序列生成对抗网络的自动驾驶汽车高速公路变道切入测试场景自动生成算法,实现了不同危险程度变道切入场景中前车变道轨迹和测试车变道切入时刻前运行轨迹的自动生成,主要工作如下。

首先,通过分析真实高速公路变道切入场景中车辆的运动轨迹,以变道切入时刻两车车头时距和侧向时距作为场景危险程度评价指标,从高速公路真实轨迹数据中提取具有较高危险程度的2853个变道切入场景实例,并将所得实例按危险程度划分为4类。

其次,基于TsGAN构建变道切入测试场景生成模型,利用所提取的实例中的真实轨迹数据训练模型。通过计算所生成的轨迹参数与真实轨迹参数

的分布误差和平均弗雷歇距离,验证所生成的轨迹与真实轨迹的相似性;引入真实轨迹缓冲区,筛选符合车辆动力学和真实驾驶人操纵特征约束的生成轨迹,确保所生成的场景的有效性;计算所生成的轨迹与真实轨迹的频谱误差,确认模型能否捕捉真实场景中车辆轨迹的变化规律。通过分析场景实例点的分布均匀度及轨迹参数的分布区间,检验场景生成算法对场景覆盖度的提升效果。

最后,利用变道切入测试场景实现不同危险程度的变道轨迹和测试车变道切入时刻前运动轨迹的同步生成,并将生成的测试场景导入PreScan虚拟测试平台,执行前车变道切入场景下的自动驾驶汽车响应控制算法测试。

通过以上研究,得到如下结论。

(1)TsGAN模型生成的场景具有高真实性。分析HD和MAE两个评价指标可知,TsGAN模型生成的变道轨迹与真实轨迹的平均相似度为79.7%,明显优于MCS算法生成的轨迹,表明TsGAN模型生成的轨迹与所采集的真实轨迹具有高相似性;TsGAN模型生成的变道轨迹与其最相似真实轨迹的平均弗雷歇距离为0.11m,相比MCS算法的减小了0.01m,落在最相似真实轨迹缓冲区的轨迹超过83.2%,证明所生成的变道轨迹能够满足真实车辆动力学和真实驾驶人操纵特征的约束;TsGAN模型生成的变道轨迹与真实轨迹的平均频谱误差小于8%,低于MCS算法的频谱误差,证明TsGAN模型能够捕捉到真实场景中的车辆轨迹动态变化。

(2)TsGAN模型生成的场景具有高覆盖度。对比TsGAN模型与MCS算法生成场景实例点分布的Rispley's K函数曲线可以发现,TsGAN模型生成场景实例点的分布均匀性明显优于MCS算法;相比所采集的真实场景实例,TsGAN模型生成场景实例的覆盖范围更大,在参数区间内的分布更加均匀。同时,相比所采集的真实场景实例,TsGAN模型生成场景实例在变道切入时刻前方变道车辆与测试车的车头时距和侧向时距分别降低了17.83%和16.37%(平均值),车辆轨迹参数分布区间平均增长了19.44%,获得了所采集的真实数据集中不存在且危险程度更高的测试场景,提升了测试场景在自然场景中的覆盖度。

(3)本文提出的基于TsGAN的变道切入测试场景生成模型可模拟4种不同危险程度的变道切入场景,所生成的测试场景具有较好的针对性,可支持自动驾驶汽车的强化测试。

为降低模型训练难度,本研究中采用了典型的两车变道模型,未考虑变道过程中周围的其他车辆。后续研究中,将关注变道切入场景中的其他背景车辆,以实现多车环境下的变道切入测试场景生成。

参考文献:

- [1] 王雪松,杨敏明.基于自然驾驶数据的变道切入行为分析[J].同济大学学报(自然科学版),2018,46(8):1057-1063.
WANG Xuesong, YANG Minming. Cut-in behavior analyses based on naturalistic driving data [J]. Journal of Tongji University (Natural Science), 2018, 46(8): 1057-1063.
- [2] 王雪松,李艳.基于自然驾驶数据的驾驶员变道特征分析[J].交通信息与安全,2016,34(1):17-22.
WANG Xuesong, LI Yan. Characteristics analysis of lane changing behavior based on the naturalistic driving data [J]. Journal of Transport Information and Safety, 2016, 34(1): 17-22.
- [3] 郭柏苍,雒国风,金立生,等.面向自动驾驶虚拟测试的变道切入场景库构建方法[J].吉林大学学报(工学版),2023,53(11):3130-3140.
GUO Bo-cang, LUO Guo-feng, JIN Li-sheng, et al. Construction method of cut-in scenario library for automatic driving virtual tests [J]. Journal of Jilin University (Engineering and Technology Edition), 2023, 53(11): 3130-3140.
- [4] XU D, DING Z, ZHAO H, et al. Naturalistic lane change analysis for human-like trajectory generation [C]//Proceedings of 2018 IEEE Intelligent Vehicles Symposium. New York: IEEE, 2018: 1393-1399.
- [5] HUANG W, LV Y, CHEN L, et al. Accelerate the autonomous vehicles reliability testing in parallel paradigm [C]//Proceedings of IEEE 20th International Conference on Intelligent Transportation Systems. Piscataway: IEEE, 2017: 922-927.
- [6] XU Z, JIANG Z, WANG G, et al. When the automated driving system fails: dynamics of public responses to automated vehicles [J]. Transportation Research Part C: Emerging Technologies, 2021, 129(4): 103271/1-13.
- [7] XU Z, WANG G, ZHAI S, et al. When automation fails: examining the effect of a verbal recovery strategy on user experience in automated driving [J]. International Journal of Human-Computer Interaction, 2023. Doi: 10.1080/10447318.2023.2176986.

- [8] GAO Y, ZHAO X, XU Z, et al. An indoor vehicle-in-the-loop simulation platform testing method for autonomous emergency braking [J]. *Journal of Advanced Transportation*, 2021, 2021: 8872889/1-12.
- [9] GELDER E, PAARDEKOOPER J. Assessment of automated driving systems using real-life scenarios [C]//*Proceedings of 2017 IEEE Intelligent Vehicles Symposium*. Piscataway: IEEE, 2017: 589-594.
- [10] JENKINS I R, GEE L, KNAUSS A, et al. Accident scenario generation with recurrent neural networks [C]//*Proceedings of IEEE 21st International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2018: 3340-3345.
- [11] ZHAO D, LAM H, PENG H, et al. Accelerated evaluation of automated vehicles safety in lane-change scenarios based on importance sampling techniques [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2017, 18(3): 595-607.
- [12] ZHAO D, HUANG X, PENG H, et al. Accelerated evaluation of automated vehicles in car-following maneuvers [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(3): 733-744.
- [13] ZHAO H, WANG C, LIN Y, et al. On-road vehicle trajectory collection and scene-based lane change analysis: Part I [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2017, 18(1): 192-205.
- [14] GUO Y, KALIDINDI V V, ARIEF M, et al. Modeling multi-vehicle interaction scenarios using Gaussian random field [C]//*Proceedings of IEEE 22th International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2019: 3974-3980.
- [15] XU Z, WANG Y, WANG G, et al. Trajectory optimization for a connected automated traffic stream: comparison between an exact model and fast heuristics [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(5): 2969-2978.
- [16] GAO Y, LI J, XU Z, et al. A novel image-based convolutional neural network approach for traffic congestion estimation [J]. *Expert Systems with Applications*, 2021, 180: 115037/1-13.
- [17] LI J, XU Z, FU L, et al. Domain adaptation from daytime to nighttime: a situation-sensitive vehicle detection and traffic flow parameter estimation framework [J]. *Transportation Research Part C: Emerging Technologies*, 2021, 124: 102946/1-19.
- [18] KRAJEWSKI R, BOCK J, KLOEKER L, et al. The highD dataset: a drone dataset of naturalistic vehicle trajectories on German highways for validation of highly automated driving systems [C]//*Proceedings of IEEE 21st International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2018: 2118-2125.
- [19] KRAJEWSKI R, MOERS T, BOCK J, et al. The roundD dataset: a drone dataset of road user trajectories at roundabouts in Germany [C]//*Proceedings of IEEE 23rd International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2020: 1-6.
- [20] BOCK J, KRAJEWSKI R, MOERS T, et al. The inD dataset: a drone dataset of naturalistic road user trajectories at German intersections [C]//*Proceedings of 2020 IEEE Intelligent Vehicles Symposium*. Piscataway: IEEE, 2020: 1929-1934.
- [21] MOERS T, VATER L, KRAJEWSKI R, et al. The exiD dataset: a real-world trajectory dataset of highly interactive highway scenarios in Germany [C]//*Proceedings of 2022 IEEE Intelligent Vehicles Symposium*. Piscataway: IEEE, 2022: 958-964.
- [22] FENG S, FENG Y, YU C, et al. Testing scenario library generation for connected and automated vehicles, Part I: methodology [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(3): 1573-1582.
- [23] FENG S, FENG Y, SUN H, et al. Testing scenario library generation for connected and automated vehicles, Part II: case studies [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(9): 5635-5647.
- [24] HUANG Z, LAM H, ZHAO D. An accelerated testing approach for automated vehicles with background traffic described by joint distributions [C]//*Proceedings of IEEE 20th International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2017: 933-938.
- [25] ROCKLAGE E, KRAFT H, KARATAS A, et al. Automated scenario generation for regression testing of autonomous vehicles [C]//*Proceedings of IEEE 20th International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2017: 476-483.
- [26] YAO W, ZHAO H, DAVOINE F, et al. Learning lane change trajectories from on-road driving data [C]//*Proceedings of 2012 IEEE Intelligent Vehicles Symposium*. Piscataway: IEEE, 2012: 885-890.
- [27] XU G, LIU L, OU Y, et al. Dynamic modeling of driver control strategy of lane-change behavior and trajectory planning for collision prediction [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2012, 13(3): 1138-1155.
- [28] WANG Z, ZHAO X, XU Z, et al. Modeling and field experiments on autonomous vehicle lane changing

- with surrounding human-driven vehicles [J]. Computer-Aided Civil and Infrastructure Engineering, 2021, 36(7): 877-889.
- [29] KRAJEWSKI R, MOERS T, NERGER D, et al. Data-driven maneuver modeling using generative adversarial networks and variational autoencoders for safety validation of highly automated vehicles [C]//Proceedings of IEEE 21st International Conference on Intelligent Transportation Systems. Piscataway: IEEE, 2018: 2383-2390.
- [30] SCHILDBACH G, BORRELLI F. Scenario model predictive control for lane change assistance on highways [C]//Proceedings of 2015 IEEE Intelligent Vehicles Symposium. Piscataway: IEEE, 2015: 611-616.
- [31] SHIWAKOTI S, BIKRAM SHAHI S, SINGH P. Deep learning methods for vehicle trajectory prediction: a survey [C]//JOBY P P, ALENCAR M S, FALKOWSKI-GILSKI P. IoT Based Control Networks and Intelligent Systems (Proceedings of 4th ICICNIS 2023). Singapore: Springer, 2023: 539-554.
- [32] 朱宇, 赵祥模, 徐志刚, 等. 基于蒙特卡洛模拟的无人车高速公路变道虚拟测试场景自动生成算法[J]. 中国公路学报, 2022, 35(3): 89-100.
- ZHU Yu, ZHAO Xiang-mo, XU Zhi-gang, et al. Automatic generation algorithm of lane-change virtual test scenario on highways for automated vehicles using Monte Carlo simulation [J]. China Journal of Highway and Transport, 2022, 35(3): 89-100.
- [33] YOON J, JARRETT D, SCHAAR M V D. Time-series generative adversarial networks [C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc, 2019: 5508-5518.
- [34] 胡远志, 吕章洁, 刘西. 基于PreScan的AEB系统纵向避撞算法及仿真验证[J]. 汽车安全与节能学报, 2017, 8(2): 136-142.
- HU Yuan-zhi, LV Zhang-jie, LIU Xi. Algorithm and simulation verification of longitudinal collision avoidance for autonomous emergency break (AEB) system based on PreScan [J]. Journal of Automotive Safety and Energy, 2017, 8(2): 136-142.
- [35] ZHANG Y, ANTONSSON E, GROTE K. A new threat assessment measure for collision avoidance systems [C]//Proceedings of IEEE 9th International Conference on Intelligent Transportation Systems. Piscataway: IEEE, 2006: 968-975.
- [36] HUANG Z, ZHAO D, LAM H, et al. Evaluation of automated vehicles in the frontal cut-in scenario—an enhanced approach using piecewise mixture models [C]//Proceedings of 2017 IEEE International Conference on Robotics and Automation. New York: IEEE, 2017: 197-202.
- [37] 朱冰, 张培兴, 赵健. 面向多维度逻辑场景的自动驾驶安全性聚类评价方法[J]. 汽车工程, 2020, 42(11): 1458-1463, 1505.
- ZHU Bing, ZHANG Peixing, ZHAO Jian. Clustering evaluation method of autonomous driving safety for multi-dimensional logical scenario [J]. Automotive Engineering, 2020, 42(11): 1458-1463, 1505.
- [38] 朱西产, 张佳瑞, 马志雄. 安全切入场景下的驾驶人初始制动时刻分析[J]. 中国公路学报, 2019, 32(6): 262-273, 318.
- ZHU Xi-chan, ZHANG Jia-rui, MA Zhi-xiong, et al. Analysis of driver initial brake time in safety cut-in scenario [J]. China Journal of Highway and Transport, 2019, 32(6): 262-273, 318.
- [39] 朱西产, 魏昊舟, 马志雄. 基于自然驾驶数据的跟车场景潜在风险评估[J]. 中国公路学报, 2020, 33(4): 169-181.
- ZHU Xi-chan, WEI Hao-zhou, MA Zhi-xiong. Assessment of the potential risk in car-following scenario based on naturalistic driving data [J]. China Journal of Highway and Transport, 2020, 33(4): 169-181.
- [40] MULDER M, ABBINK D A, VAN PAASSEN M M, et al. Design of a haptic gas pedal for active car-following support [J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(1): 268-279.
- [41] 马依宁, 姜为, 吴靖宇, 等. 基于不同风格行驶模型的自动驾驶仿真测试自演绎场景研究[J]. 中国公路学报, 2023, 36(2): 216-228.
- MA Yi-ning, JIANG Wei, WU Jing-yu, et al. Self-evolution scenarios for simulation tests of autonomous vehicles based on different models of driving styles [J]. China Journal of Highway and Transport, 2023, 36(2): 216-228.
- [42] 卢胜, 王正刚, 李纯厚. 频谱相似性目标识别算法[J]. 声学技术, 2010, 29(1): 94-98.
- LU Sheng, WANG Zheng-gang, LI Chun-hou. An algorithm for object discrimination by spectra similarity [J]. Technical Acoustics, 2010, 29(1): 94-98.
- [43] 王结臣, 卢敏, 苑振宇, 等. 基于Ripley's K 函数的南京市ATM网点空间分布模式研究[J]. 地理科学, 2016, 36(12): 1843-1849.
- WANG Jiechen, LU Min, YUAN Zhenyu, et al. Point pattern analysis of ATMs distribution based on Ripley's K -function method in Nanjing City [J]. Sci-

- tia Geographica Sinica, 2016, 36(12): 1843-1849.
- [44] 葛莹, 刘尉, 李勇. Ripley's K 函数方法修正与估计方法比较 [J]. 武汉大学学报(信息科学版), 2023, 48(6): 970-978.

GE Ying, LIU Wei, LI Yong. Algorithm modification and estimation comparison of Ripley's K -function [J]. Geomatics and Information Science of Wuhan University, 2023, 48(6): 970-978.

TsGAN-Based Automatic Generation Algorithm of Lane-Change Cut-in Test Scenarios on Expressways for Autonomous Vehicles

ZHU Yu¹ XU Zhigang¹ ZHAO Xiangmo¹ WANG Runmin¹ QU Xiaobo²

(1. IoV and CAV Testing Technology Research Institute, Chang'an University, Xi'an 710018, Shaanxi, China;

2. School of Vehicle and Mobility, Tsinghua University, Beijing 100084, China)

Abstract: The event wherein vehicles from the adjacent lane execute a lane-change maneuver, cutting into the lane occupied by autonomous vehicles, epitomizes a typical high-risk scenario on expressways within the domain of autonomous driving. Replicating such scenarios for testing on actual expressways involves significant safety risks. Virtual simulation test is one of the best approaches to addressing this issue. In order to automatically generate mass high-fidelity expressway lane-change cut-in test scenarios, this paper presents an automatic generation algorithm of lane-change cut-in test scenarios for autonomous vehicles based on TsGAN (Time-Series Generative Adversarial Network). In this algorithm, the time headway and lateral gap at the cut-in moment are taken as the evaluation metrics for scenario risk assessment, and 2 853 instances of lane-change cut-in scenarios with four different risk levels are extracted from the real expressway trajectory dataset highD. A model for generating lane-change cut-in test scenarios is established based on TsGAN, and is trained with the extracted real trajectory data. Then, the model is employed to generate the trajectories for the lane-change vehicle and the tested vehicle before the cut-in moment. To authenticate the generated trajectories, the distribution similarity and spectral error between the generated and the real trajectories are compared. Furthermore, an in-depth analysis of the kinematic interplay between the two vehicles at the cut-in moment and the distribution of trajectory parameters in the generated scenarios is performed to validate the coverage of the generated scenarios within naturalistic settings. The findings can be summarized as follows: (1) as illustrated by the distribution of key trajectory parameters, the average similarity between the generated and the real lane-change trajectories is 79.7%, with an average spectral error less than 8%, and more than 83.2% of the generated trajectories are within the buffer of the most analogous real trajectories, indicating a notable fidelity of the generated trajectories; (2) as compared with the collected real scenarios, the generated instances exhibit a more expansive coverage and a more even distribution within parameter intervals, and the time headway and lateral gap between the lane-change vehicle and the tested vehicle at the cut-in moment decrease by 17.83% and 16.37% in average, respectively, the distribution range of trajectory parameters expands by 19.44%, signifying a heightened coverage of the generated scenarios; and (3) the proposed TsGAN-based generation model has the capability of emulating lane-change cut-in test scenarios with four different risk levels, exhibiting pronounced specificity.

Key words: traffic engineering; autonomous vehicle; lane-change cut-in; virtual test scenario; generative adversarial network

责任编辑: 傅晓琴