

面向安全关键事件的自动驾驶长尾测试分布构建与稀有风险估计

蒋拯民^{1,2,3}, 李嘉昊¹, 李明鑫¹, 李慧云^{4,*}, 潘毅³, 汪建平^{1,*}

¹ (香港城市大学计算机科学系, 香港特别行政区 999077)

² (香港城市大学物质科学研究院 (福田), 深圳市 518045)

³ (深圳理工大学计算机科学与人工智能学院, 深圳市 518055)

⁴ (深圳理工大学算力微电子学院, 深圳市 518055)

摘要: 针对自动驾驶在低频高风险场景中的安全性能难以有效评估的问题, 本文提出一种新的面向安全关键事件的长尾安全测试方法, 将有限尾部事件观测转化为可采样的测试分布, 并估计被测系统的稀有风险概率。具体而言, 本文以开源高速公路自然驾驶数据为例, 面向跟驰和切入两类代表性场景构建事件级风险变量, 并采用广义帕累托尾部模型刻画人类驾驶风险尾部, 从而确定安全关键阈值; 在此基础上, 进一步利用高斯 Copula 拟合尾部场景条件变量的联合分布, 并通过条件扩散模型生成目标车连续动作轨迹, 以构建可采样的长尾测试分布。随后, 本文在场景条件与扩散潜变量联合空间中执行子集模拟, 估计被测自动驾驶系统达到安全关键风险水平的条件概率。实验表明, 所构建的长尾测试分布在关键动作统计量和交互状态分布上与自然驾驶尾部样本保持较好统计一致性。相较直接 Monte Carlo 方法, 子集模拟以更少闭环评估次数获得与 Monte Carlo 方法接近的估计, 其中跟驰和切入场景下的安全关键条件概率分别为 0.0025 和 0.0068。经风险强度换算后, 对应的 ADS 风险重现里程分别为 2366.41 km 和 16392.32 km, 分别为 highD 人类驾驶目标重现里程的 7.89 倍和 5.46 倍。表明被测自动驾驶系统的安全水平显著高于自然驾驶数据集中的人类驾驶基准。

关键词: 自动驾驶; 安全测试; 极值理论; 扩散模型; 子集模拟

中图分类号: TP391

Long-Tail Test Distribution Construction and Rare-Event Risk Estimation for Safety-Critical Events in Autonomous Driving

JIANG Zhengmin^{1,2,3}, LI Jiahao¹, LI Mingxin¹, LI Huiyun^{4,*}, PAN Yi³, WANG Jianping^{1,*}

¹ (Department of Computer Science, City University of Hong Kong, Hong Kong, China)

² (Matter Science Research Institute (Futian), City University of Hong Kong, Shenzhen, China)

³ (College of Computer Science and Artificial Intelligence, Shenzhen University of Advanced Technology, Shenzhen, China)

⁴ (College of Computability Microelectronics, Shenzhen University of Advanced Technology, Shenzhen, China)

Corresponding Author: Huiyun Li and Jianping Wang. Shenzhen University of Advanced Technology, Shen-

基金项目: 香港研究资助局优配研究项目 (11219624); 国家自然科学基金项目 (92473112)。

作者简介: 蒋拯民, 工学博士, 研究方向为自动驾驶安全, E-mail: zhengmin.jiang@cityu.edu.hk; 李慧云 (通讯作者), 教授, 研究方向为算力微电子与自动驾驶, E-mail: huiyun.li@suat-sz.edu.cn; 潘毅, 讲席教授, 研究方向为人工智能, E-mail: panyi@suat-sz.edu.cn; 汪建平 (通讯作者), 讲席教授, 研究方向为自动驾驶, E-mail: jianwang@cityu.edu.hk

zhen, China; City University of Hong Kong, Hong Kong, China. E-mail: huiyun.li@suat-sz.edu.cn, jian-wang@cityu.edu.hk.

Abstract: Evaluating autonomous driving systems (ADS) in low-frequency, high-risk scenarios remains challenging because safety-critical events are scarce in naturalistic driving data. This paper proposes a long-tail safety testing method that converts limited tail observations into a test distribution and estimates the rare-event probability of the system under test. Using open-source highway naturalistic driving data, event-level risk variables are constructed for two representative scenarios, car-following and cut-in. A peaks-over-threshold generalized Pareto tail model is then fitted to human-driving risk tails to establish an extreme value theory (EVT) risk scale and determine safety-critical thresholds. Based on the identified tail events, a Gaussian Copula is used to model the joint distribution of scenario-condition variables, and a conditional diffusion action model is trained to generate continuous target-vehicle action trajectories. Subset simulation is further performed in the joint space of scenario conditions and diffusion latents to estimate the conditional probability that the tested ADS reaches the safety-critical risk level under the constructed long-tail test distribution. Experiments show that the generalized Pareto tail model effectively characterizes the high-risk tails of the car-following and cut-in risk variables, and that the generated samples are consistent with naturalistic tail samples in key action statistics and interaction-state distributions. Compared with direct Monte Carlo, subset simulation yields comparable estimates with fewer closed-loop evaluations while preserving the target probability definition: the safety-critical conditional probabilities are 0.0025 for car-following and 0.0068 for cut-in. After safety-critical risk-intensity conversion, the corresponding ADS risk-return mileage values are 2366.41 km and 16392.32 km, which are 7.89 and 5.46 times the human-driving risk-return mileage values under the same thresholds and exposure definitions, respectively. These results indicate that, under the constructed long-tail test distribution, the tested ADS exhibits a lower safety-critical risk intensity than the human-driving baseline in the naturalistic driving dataset.

Key words: Autonomous Driving; Safety Testing; Extreme Value Theory; Diffusion Model; Subset Simulation

Funding: This project is supported by the Hong Kong Research Grants Council under General Research Fund (Grant No. 11219624) and the National Natural Science Foundation of China (NSFC) under Grant 92473112.

1 引言

自动驾驶系统 (autonomous driving system, ADS) 的性能安全不仅取决于常规交通场景中的平均表现, 更取决于其在低频、高风险长尾场景中的行为响应^[1;2]。由于真实道路中的安全关键事件极为稀少, 单纯依赖道路测试或离线回放难以在有限预算内充分暴露被测 ADS 的高风险行为边界, 也难以量化其发生安全关键事件的概率。

为提高自然驾驶尾部风险的暴露效率, 现有研究重点关注基于仿真场景生成的安全测试方法。例如, AdvSim 和 KING 分别通过背景车辆扰动搜索与可微分运动学优化诱发 ADS 失效^[3;4]; TrafficGen、DriveSceneGen 等方法通过学习交通先验提高场景多样性与危险性^[5;6]; 近年来, 扩散模型进一步被用于可控交通仿真^[7;8;9;10]。此外, 面向感知测试的风险场景生成也从因果因素组合角度揭示了自动驾驶模块的脆弱性^[11]。在高速公路变道切入等典型交互中, 赵祥模等利用 BN-AM-SeqGAN、TsGAN 等生成式 AI 模型泛化危险切入测试场景^[12;13]。上述方法提高了危险样本的发掘效率, 但当生成场景逐渐偏离自然驾驶尾部行为分布时, 所

得风险结果便难以解释为自然驾驶统计参照下的发生概率。

自然驾驶数据为驾驶风险尾部建模提供了必要的统计参照。通过学习真实车辆的运动模式，可以使仿真测试在碰撞率、近失率、速度和车距等统计量上接近自然驾驶环境，从而构造更合理的测试场景^[14;15;16]。例如，将自然驾驶分布与重要性采样或强化学习结合，则能够在保留相对于原始采样分布的概率解释的同时，提高安全关键事件暴露效率^[17;18]。然而，自然驾驶数据本质上是离线观测数据，即有限的尾部事件并不能直接构成可重复采样、可闭环执行的测试输入。因此，仅依赖自然驾驶尾部样本回放会受限于有限观测覆盖，而直接对驾驶行为进行对抗优化又可能破坏关键动作统计量与交互状态分布的驾驶一致性。

值得注意的是，实践中往往还需要进一步估计被测 ADS 在长尾测试分布下达到安全关键风险水平的概率。为此，有必要将连续交互轨迹转化为可比较的事件级风险变量，并确定何种风险水平可被视为安全关键。碰撞时间（time-to-collision, TTC）、车头时距（time headway, THW）和避免碰撞减速度（deceleration rate to avoid collision, DRAC）等代理安全度量虽能刻画局部交互危险性^[19]，但若直接采用固定经验阈值，则难以反映不同逻辑场景中人类驾驶风险尾部的统计差异。此外，安全关键事件即便在筛选后的长尾测试分布中也依然稀疏，传统失效估计方法（如直接 Monte Carlo 采样）需要大量评估预算；研究者常用的代理模型与重要性采样方法通常依赖低维参数空间或有限离线危险样本集合^[20]，在高维测试空间下容易受到采样效率与概率解释性的限制。

综上所述，现有研究仍存在以下不足：一方面，危险场景生成方法虽能提高安全关键事件的发现效率，但生成场景与自然驾驶风险尾部之间缺乏明确的概率对应关系，因而难以形成可比较的风险度量；另一方面，自然驾驶建模与加速测试方法虽具备一定概率解释基础，但多受限于离线样本回放、低维参数扰动或固定场景族，难以刻画连续动作轨迹与交互条件共同形成的高维测试空间。因此，自动驾驶长尾安全测试的关键不应仅是生成更多危险场景，更应基于自然驾驶尾部的统计参照构建可采样的测试分布，并进一步量化被测 ADS 在该分布下达到安全关键风险水平的条件概率。

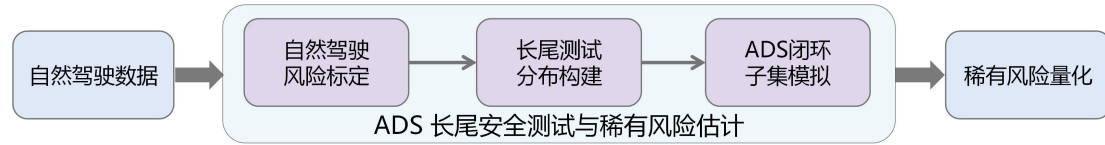


图 1 自动驾驶长尾安全测试与稀有风险估计框架

Fig. 1 Framework of long-tail safety testing and rare-risk estimation of autonomous driving systems

为此，本文基于开源 *highD* 自然驾驶数据集^[21]，提出了一种融合极值理论（extreme value theory, EVT）、扩散模型和子集模拟的自动驾驶长尾风险测试与概率评估框架，如图 1 所示。该方法首先在 EVT 框架下采用超阈值-广义帕累托分布（peaks-over-threshold generalized Pareto distribution, POT-GPD）尾部模型刻画人类驾驶风险尾部；并基于尾部场景条件变量联合分布与条件扩散模型，构建可采样且保持自然驾驶行为约束的长尾测试分布；最后在场景条件与扩散潜变量联合空间中执行闭环子集模拟，估计被测 ADS 达到安全关键风险水平的条件概率。本文的主要贡献如下：

- （1）**自然驾驶风险标定**：面向跟驰与切入两类代表性场景，基于多维代理安全度量构建事件级风险变量；采用 POT-GPD 尾部模型刻画自然驾驶风险变量的尾部，从而为后续测试提供具有概率语义的风险参照；
- （2）**长尾测试分布构建**：采用高斯 Copula 拟合尾部场景条件的联合分布并通过条件扩散模型学习给定场景条件下目标车的连续动作生成规律，从而构建由场景条件采样与目标车动作生成共同定义的长尾测试分布；

- (3) **稀有风险概率估计**: 面向所构建的长尾测试分布, 在场景条件与扩散潜变量联合空间中引入子集模拟, 通过逐层条件采样高效探索安全关键域, 估计被测 ADS 达到安全关键风险水平的条件概率。

2 方法

本节首先应用极值理论对自然驾驶事件的风险变量进行尾部建模, 采用 POT-GPD 模型刻画风险样本的尾部分布, 并据此构建风险尺度、确定安全关键阈值; 随后提取场景条件变量, 利用高斯 Copula 拟合其联合分布, 并通过条件扩散模型生成目标车的连续动作轨迹, 从而形成可采样的长尾测试分布。最后, 在场景条件与扩散潜变量联合空间中引入子集模拟, 估计被测 ADS 在该长尾测试分布下达到安全关键风险水平的条件概率。

2.1 驾驶事件筛选与风险校准

为建立具有自然驾驶统计含义的尾部风险参照, 本文采用开源 *highD* 数据集^[21] 作为自然驾驶行为数据来源, 并参考风险驾驶场景提取规则^[22], 选取跟驰和切入两类代表性功能场景。其中跟驰场景刻画车距压缩与前车制动引发的纵向追尾风险, 切入场景刻画相邻车道车辆并入后对主车形成的横纵向耦合风险。后文以 $e \in \{\text{cf}, \text{ci}\}$ 分别表示跟驰与切入事件类型。

在事件抽取阶段, 本文首先对原始轨迹进行行驶方向归一化和物理异常过滤, 仅保留小客车交互且语义明确的原始驾驶片段。对于跟驰事件, 要求主车在连续时间片段内具有同一前车, 两车同车道比例不低于 80%, 且中位跟车间距大于 0.5 m。对于切入事件, 检测目标车由相邻车道并入目标车道的过程, 并匹配切入后最近的主车; 要求换道前后具有稳定车道片段, 跨线后至少有 2.0 s 轨迹重叠, 且切入后两车同车道比例不低于 70%。随后, 将每段交互轨迹压缩为可排序的事件级风险变量。记 $\tau_{a:b} = \{s_{\text{ego}}^t, s_{\text{tar}}^t\}_{t=a}^b$ 为时间区间 $[a, b]$ 内主车与目标车的交互轨迹片段, 默认计分片段记为 $\tau = \tau_{0:T}$, ego 表示被风险作用的车辆; 在闭环测试中, 该车辆由主车 (即被测 ADS 车辆) 替代。 tar 表示目标车, 在跟驰场景中为前车, 在切入场景中为切入车。

对于跟驰事件, 本文对各代理安全指标进行归一化与时序池化, 并将其聚合为事件级纵向风险得分:

$$Y_{\text{long}}(\tau) = \mathbf{w}_{\text{long}}^{\top} \mathbf{r}_{\text{long}}(\tau) + \lambda_C C(\tau) + \lambda_N N(\tau) + \lambda_B B(\tau) \quad (1)$$

式中, $\mathbf{r}_{\text{long}}(\tau)$ 为经归一化和时序池化后的纵向代理安全度量向量, 包含 TTC、THW、跟车间距和 DRAC 等分量; $\mathbf{w}_{\text{long}}$ 为对应权重向量; $C(\tau)$ 、 $N(\tau)$ 和 $B(\tau)$ 分别表示碰撞、近碰撞和急制动强度; λ_C 、 λ_N 和 λ_B 为相应权重。

对于切入事件, 将目标车跨越车道线的时刻记为 t_{cutin} 。切入后的纵向风险仍按式 (1) 计算, 但风险聚合区间限定为 $\tau_{t_{\text{cutin}}:T}$ 。为刻画目标车向主车所在车道快速并入所产生的横向迫近风险, 本文基于横向剩余距离 $d_{\perp}^t$ 和非负横向接近速度 $v_{\perp}^t$ 计算横向到达时间 $\Delta t_{\perp}^t = d_{\perp}^t / \max(v_{\perp}^t, \epsilon_v)$, 并对 t_{cutin} 后短时间窗内的 $1 / \max(\Delta t_{\perp}^t, \epsilon_L)$ 进行与纵向代理安全度量一致的时序池化和尺度归一化, 得到横向风险项 $L_{\text{lat}}(\tau; t_{\text{cutin}})$ 。

$$Y_{\text{cutin}}(\tau) = Y_{\text{long}}(\tau_{t_{\text{cutin}}:T}) + \lambda_L L_{\text{lat}}(\tau; t_{\text{cutin}}) \quad (2)$$

式中, λ_L 为横向风险权重, ϵ_v 和 ϵ_L 为数值下界。后文统一用 $Y_e(\tau)$ 表示事件级风险得分, x 表示与 Y_e 同一尺度上的原始风险取值: 当 $e = \text{cf}$ 时, x 是 Y_{long} 的取值; 当 $e = \text{ci}$ 时, x 是 Y_{cutin} 的取值。

安全关键事件通常对应于事件风险变量 $Y_e(\tau)$ 分布尾侧的低频高风险区域。为获得具有自然驾驶统计含义的风险参照, 本文采用 POT-GPD 模型刻画 *highD* 人类驾驶事件风险

的尾部分布，并根据目标超越概率反解安全关键阈值。具体设事件类型 e 下的 *highD* 人类驾驶风险样本为 $\mathcal{Y}_e = \{Y_{e,i}\}_{i=1}^n$ ，并在该样本上选取 POT 尾部建模阈值 u_e 。根据 Pickands–Balkema–de Haan 定理^[23;24]，当 u_e 足够高时，条件超额量 $Y_e - u_e \mid Y_e > u_e$ 可由 GPD 近似。令 $\hat{\alpha}_e = n^{-1} \sum_{i=1}^n \mathbb{I}\{Y_{e,i} > u_e\}$ 为样本经验超额率，则事件类型 e 下 *highD* 人类驾驶风险的尾部生存函数可写为

$$Q_e(x) = \Pr(Y_e > x) \approx \hat{\alpha}_e \begin{cases} (1 + \xi_e(x - u_e)/\beta_e)^{-1/\xi_e}, & \xi_e \neq 0, \\ \exp[-(x - u_e)/\beta_e], & \xi_e = 0, \end{cases} \quad x > u_e \quad (3)$$

式 (3) 中， ξ_e 和 β_e 分别为 GPD 的形状参数和尺度参数； $Q_e(x)$ 表示同类 *highD* 人类驾驶事件风险超过取值 x 的尾部概率。 $Q_e(x)$ 越小，说明该风险水平在自然驾驶尾部中越罕见，其安全关键程度越高。实际拟合中，阈值 u_e 结合均值剩余寿命、GPD 参数稳定性、QQ/PP 图和尾部生存函数拟合效果综合确定。

拟合得到 $Q_e(x)$ 后，本文根据预设风险重现水平对应的尾部超越概率 π_e^* ，反解得到安全关键原始风险阈值 x_e^* 。进一步定义 EVT 风险尺度 $S_e(x) = -\log Q_e(x)$ ，将原始风险值映射为其在自然驾驶尾部中的罕见程度；该变换不改变风险排序。由此，安全关键阈值在 EVT 风险尺度上的对应值为：

$$\begin{cases} x_e^* = \begin{cases} u_e + \frac{\beta_e}{\xi_e} \left[\left(\frac{\hat{\alpha}_e}{\pi_e^*} \right)^{\xi_e} - 1 \right], & \xi_e \neq 0, \\ u_e + \beta_e \log \left(\frac{\hat{\alpha}_e}{\pi_e^*} \right), & \xi_e = 0, \end{cases} \\ \gamma_e^* = S_e(x_e^*) \end{cases} \quad (4)$$

后续闭环测试中，当 $S_e(Y_e(\tau)) \geq \gamma_e^*$ 时，判定被测 ADS 达到安全关键风险水平。

2.2 长尾测试分布构建

第 2.1 节通过 POT-GPD 尾部建模获得了自然驾驶风险尾部及其安全关键阈值。然而，经 POT 阈值筛选得到的尾部事件仍是数量有限的原始回放轨迹，其中场景初始状态、目标车动作与人类驾驶主车响应相互耦合，难以直接形成被测 ADS 闭环评估所需的可重复采样测试场景。为此，本节将尾部事件分解为场景条件与目标车动作两个部分：首先从尾部事件中提取低维场景条件并拟合其联合分布，随后在给定场景条件下利用条件扩散模型生成目标车连续动作轨迹，从而构建由场景条件采样与动作生成共同定义的长尾测试分布。图 2 概括了长尾测试分布采样与闭环评估流程。

具体而言，场景条件由初始状态和目标车行为语义特征组成，其中行为语义特征用于描述生成动作所对应的制动、速度变化或切入过程。例如对于跟驰场景，7 维场景条件向量定义为

$$\mathbf{o}_{cf} = [v_{x,ego}^0, g_0, \Delta v_x^0, a_{x,tar}^0, \Delta v_{x,tar}^T, a_{x,tar}^{\min}, \tau_{b,tar}]^T \in \mathbb{R}^7 \quad (5)$$

式中，上标 0 表示仿真初始时刻， T 表示生成时域终末时刻，此时目标车的动作序列为纵向加加速度 (jerk)，生成时域长度为 $H = 125$ 帧。 $g_0 = x_{tar}^0 - x_{ego}^0 - \frac{1}{2}(L_{ego} + L_{tar})$ 为初始纵向相对距离， $\Delta v_x^0 = v_{x,ego}^0 - v_{x,tar}^0$ 为初始纵向相对速度， $\Delta v_{x,tar}^T = v_{x,tar}^T - v_{x,tar}^0$ 为前车速度变化量， $a_{x,tar}^{\min} = \min_{t \in [0, T]} a_{x,tar}^t$ 为前车在生成时域内的最小纵向加速度， $\tau_{b,tar} = \sum_{t=0}^T \mathbb{I}(a_{x,tar}^t < 0) \Delta t$ 为前车制动持续时间。对于切入场景，10 维场景条件向量定义为

$$\mathbf{o}_{ci} = [v_{x,ego}^0, g_0, d_y^0, \Delta v_x^0, a_{x,tar}^0, v_{y,tar}^0, a_{y,tar}^0, d_y^T, t_{cross}, \Delta v_{x,tar}^T]^T \in \mathbb{R}^{10} \quad (6)$$

切入场景中目标车动作序列为二维加速度（纵向加速度和横向加速度），生成时域长度 $H = 100$ 帧。 $g_0 = x_{tar}^0 - x_{ego}^0 - \frac{1}{2}(L_{ego} + L_{tar})$ 为初始纵向相对距离， $d_y^0 = y_{tar}^0 - y_{ego}^0$ 为初始横向偏

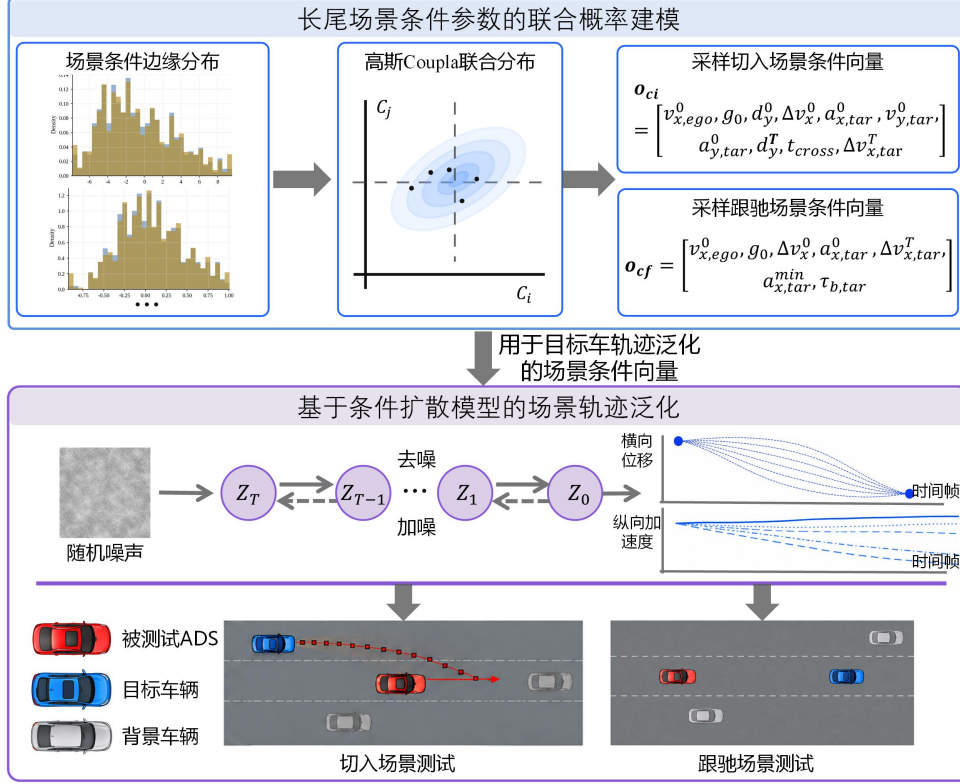


图 2 长尾测试分布采样与闭环评估流程

Fig. 2 Long-tail test distribution sampling and closed-loop evaluation workflow

移, $\Delta v_x^0 = v_{x,ego}^0 - v_{x,tar}^0$ 为初始纵向相对速度, $d_y^T = y_{tar}^T - y_{ego}^T$ 为终端横向偏移, t_{cross} 为从初始时刻到切入车跨越车道边界的时间, $\Delta v_{x,tar}^T = v_{x,tar}^T - v_{x,tar}^0$ 为切入车速度变化量。

在上述场景条件定义下, 基于第 2.1 节中的 POT 建模阈值 u_e , 事件类型 e 的尾部事件集合及其对应的场景条件样本集合定义为

$$\begin{cases} \mathcal{T}_e = \{\tau_i : Y_e(\tau_i) > u_e\}, \\ \mathbf{o}_{e,i} = \phi_e(\tau_i), \\ \mathcal{O}_e = \{\mathbf{o}_{e,i} : \tau_i \in \mathcal{T}_e\}, \end{cases} \quad (7)$$

其中, $\phi_e(\tau_i)$ 表示从尾部事件 τ_i 中提取场景条件向量; 当 $e = cf$ 时对应式 (5), 当 $e = ci$ 时对应式 (6)。记由 $\mathcal{O}_e$ 拟合得到的场景条件联合分布为 $\mathcal{D}_e$ 。本文采用高斯 Copula (Gaussian Copula) 对 $\mathcal{D}_e$ 进行建模: 拟合时保留各条件变量的经验边缘分布, 并在正态分位空间估计相关结构; 采样时通过经验分位函数将样本反变换回物理量空间。由此, $\mathcal{D}_e$ 同时约束尾部场景条件的边缘分布与相关结构, 避免逐维独立采样。采样得到的 $\mathbf{o}_e \sim \mathcal{D}_e$ 既作为扩散模型的条件输入, 也用于设置闭环仿真场景的初始状态。

在给定场景条件 $\mathbf{o}_e$ 后, 还需生成符合自然驾驶行为特征的目标车时序动作。本文采用条件扩散模型学习场景条件下的目标车动作分布, 并由扩散潜变量 z 表达同一场景条件下未被显式固定的微观动作差异。训练阶段采用去噪扩散概率模型 (denoising diffusion probabilistic model, DDPM), 推理阶段采用去噪扩散隐式模型 (denoising diffusion implicit model, DDIM) 进行确定性采样。DDPM 训练时将高斯噪声逐步注入自然驾驶动作序列, 去噪网络在场景条件约束下预测注入噪声; 该网络由特征线性调制 (feature-wise linear modulation, FiLM) 条件变换器参数化, 使 $\mathbf{o}_e$ 能够调制动作序列表示。模型训练样本来源于第 2.1 节事件抽取后形成的 *highD* 跟驰与切入片段。设训练样本中的自然驾驶目标车动作序列为 $\mathbf{a}_0$; 扩散步为

k , 噪声为 $\epsilon \sim \mathcal{N}(0, I)$, 则训练目标可概括为

$$\begin{cases} \mathcal{L}_{\text{diff}} = \mathbb{E} \left[\|\epsilon - \epsilon_\theta(\mathbf{a}_k, k, \mathbf{o}_e)\|_2^2 \right] + \lambda_0 \|\hat{\mathbf{a}}_0 - \mathbf{a}_0\|_1 + \lambda_s \sum_{h=2}^H \|\hat{\mathbf{a}}_{0,h} - \hat{\mathbf{a}}_{0,h-1}\|_1 + \mathcal{L}_{\text{ci}}, \\ \mathbf{a}_k = \sqrt{\bar{\alpha}_k} \mathbf{a}_0 + \sqrt{1 - \bar{\alpha}_k} \epsilon, \end{cases} \quad (8)$$

其中 ϵ_θ 为条件去噪网络, $\hat{\mathbf{a}}_0$ 为由噪声预测反推得到的目标车动作序列, λ_0 和 λ_s 分别控制动作重建与平滑约束。对于切入场景, $\mathcal{L}_{\text{ci}}$ 进一步约束终端横向偏移、跨线后车道保持和横向加加速度; 对于跟驰场景, 该项取零。训练阶段按记录划分训练集、验证集和测试集, 并以验证集性能进行模型选择。闭环评估阶段, 从 $\mathcal{D}_e$ 抽取尾部场景条件, 冻结扩散模型参数, 并采用确定性 DDIM 解码:

$$\mathbf{a}_{1:H} = G_\theta(\mathbf{o}_e, z), \quad z \sim \mathcal{N}(0, I) \quad (9)$$

总之, $\mathbf{o}_e$ 决定测试场景的尾部语义和仿真初始环境, z 表达同一场景条件下未被观测到的自然动作差异; 在固定模型参数 θ 后, 同一 $(\mathbf{o}_e, z)$ 对应唯一的目标车动作序列。因此, 本文将事件类型 e 的长尾测试分布定义为

$$\mathbb{P}_e := \mathcal{D}_e \otimes \mathcal{N}(0, I), \quad (10)$$

其中, $G_\theta(\mathbf{o}_e, z)$ 表示在给定场景条件与扩散潜变量下生成目标车动作轨迹的条件扩散模型。 $\mathbb{P}_e$ 作为后续子集模拟的采样分布。

2.3 基于子集模拟的稀有风险估计

对于事件类型 e , 一个闭环评估样本可表示为 $X = (\mathbf{o}_e, z) \sim \mathbb{P}_e$, 其中 $\mathbf{o}_e \sim \mathcal{D}_e$ 表示尾部场景条件, $z \sim \mathcal{N}(0, I)$ 表示同一场景条件下未被显式固定的目标车动作差异。给定 X 后, 目标车动作序列由式 (9) 生成, 被测 ADS 随后在闭环仿真环境 $\mathcal{M}_{\text{ADS}}$ 中作出响应。相应的闭环轨迹及风险得分定义为

$$\begin{cases} \tau_{\text{ADS}}(X) = \mathcal{M}_{\text{ADS}}(\mathbf{o}_e, \mathbf{a}_{1:H}(X)), \\ Y_e^{\text{ADS}}(X) = Y_e(\tau_{\text{ADS}}(X)), \\ R_e(X) = S_e(Y_e^{\text{ADS}}(X)) \end{cases} \quad (11)$$

其中, $Y_e^{\text{ADS}}(X)$ 表示被测 ADS 在闭环轨迹上的事件级原始风险得分; $R_e(X)$ 为其经 EVT 风险尺度 $S_e(\cdot)$ 转换后的风险得分, 用于表征该闭环风险相对于 *highD* 人类驾驶风险尾部的罕见程度, 这里的 $S_e(\cdot)$ 与第 2.1 节中安全关键风险尺度阈值 γ_e^* 保持一致。本文的估计目标是被测 ADS 在长尾测试分布 $\mathbb{P}_e$ 下达到安全关键风险水平的条件概率:

$$p_e = \Pr_{X \sim \mathbb{P}_e} (R_e(X) \geq \gamma_e^*) \quad (12)$$

其中, γ_e^* 为式 (4) 得到的安全关键风险尺度阈值。由于 $S_e(\cdot)$ 不改变原始风险排序, 上式等价于 $Y_e^{\text{ADS}}(X) \geq x_e^*$, 其中 x_e^* 是对应的安全关键原始风险阈值。记安全关键条件事件为 $F_e^* = \{X : R_e(X) \geq \gamma_e^*\}$ 。

尽管 $\mathbb{P}_e$ 已聚焦于自然驾驶尾部场景, 安全关键条件事件 F_e^* 在该分布下仍然稀疏。直接 Monte Carlo 采样虽然保持目标分布不变, 但在有限闭环仿真预算下难以获得足够的安全关键样本, 导致估计方差较大。为在保持同一条件概率定义的前提下提高评估效率, 本文在 X 空间中采用子集模拟^[25], 即对 F_e^* 的概率估计转化为一列中间事件上的条件采样问题。在第 k 层有 N 个样本 $\{X_i^{(k)}\}_{i=1}^N$, 将其风险得分的经验 $(1 - p_0)$ 分位数记为 b_k , 并构造中间事件 $F_k = \{X : R_e(X) \geq b_k\}$, 其中 p_0 为预设条件概率水平。每层保留得分最高的 $p_0 N$ 个

精英样本，并以这些样本为起点，通过随机游走 Metropolis 转移生成服从 $\mathbb{P}_e(\cdot | F_k)$ 的下一层条件样本。转移过程在场景条件更新与扩散潜变量扰动之间切换，候选样本需满足当前中间事件约束；同时记录接受率、唯一上下文数和唯一状态数等诊断量，以检查条件采样的稳定性。子集模拟在第 ℓ 层终止。若经验阈值已达到安全关键风险水平，即 $b_\ell \geq \gamma_e^*$ ，则利用当前层样本估计安全关键条件事件在该层中的比例，并得到

$$\hat{p}_e = p_0^\ell \frac{1}{N} \sum_{i=1}^N \mathbb{I}\{R_e(X_i^{(\ell)}) \geq \gamma_e^*\} \quad (13)$$

为了与 *highD* 人类驾驶基准在相同暴露口径下比较，本文将 $\hat{p}_e$ 换算为里程归一化的安全关键风险强度。需要强调的是， $\hat{p}_e$ 仍表示被测 ADS 在长尾测试分布 $\mathbb{P}_e$ 下达到安全关键风险水平的条件概率；下式仅将其与 *highD* 中同类尾部事件的暴露率相结合。设事件类型 e 的 *highD* 风险暴露量为 $\mathcal{E}_e$ ；令 $\mathcal{T}_e$ 为第 2.2 节定义的 *highD* 尾部事件集合，则

$$\begin{cases} \rho_e = \frac{|\mathcal{T}_e|}{\mathcal{E}_e}, \\ \hat{\lambda}_e = \hat{p}_e \rho_e. \end{cases} \quad (14)$$

其中， ρ_e 表示同类尾部事件的暴露率， $\hat{\lambda}_e$ 表示被测 ADS 在该暴露口径下的安全关键风险强度。当 $\mathcal{E}_e$ 以里程计时， $\hat{\lambda}_e$ 的单位为每千米，其倒数 $1/\hat{\lambda}_e$ 可解释为平均风险重现里程。

综上，本小节以第 2.1 节标定的安全关键阈值为风险判别基准，以第 2.2 节构建的长尾测试分布为采样分布，通过子集模拟估计被测 ADS 达到安全关键风险水平的条件概率，并进一步换算得到安全关键风险强度和风险重现里程。

3 实验与结果

实验重点讨论自然驾驶数据能否稳定构建 EVT 风险尺度并确定安全关键阈值 γ_e^* ，条件扩散模型诱导的长尾测试分布是否保持自然驾驶行为特征，以及子集模拟能否在闭环仿真中有效估计被测 ADS 的安全关键条件概率。实验基于开源高速公路仿真平台 *highway-env* 开展，仿真频率为 25 Hz。

3.1 人类驾驶风险尾部分析

表 1 *highD* 跟驰与切入事件筛选统计

Table 1 Event filtering statistics for car-following and cut-in scenarios in *highD*

场景类型	原始事件数	窗口剔除数	评分候选数	语义筛除数	可用驾驶事件
跟驰场景	73323	0	73323	0	73323
切入场景	4640	330	4310	404	3906

注：窗口剔除数为无法形成固定风险评分窗口的事件数；语义筛除数为未通过场景语义规则的候选数。

根据第 2.1 节的事件抽取与风险评分流程，*highD* 数据首先筛选出如表 1 所示的两类高速公路交互事件。跟驰场景在 5.0 s 固定窗口下保留 73323 个可用事件；切入场景从 4640 个原始逻辑事件中得到 3906 个可用事件，其中 330 个事件无法形成统一 4.0 s 评分窗口，404 个候选未通过切入语义检验。事件级风险评分后，POT-GPD 尾部模型拟合结果如表 2 所示。跟驰和切入分别得到 7546 个和 399 个 POT 超阈样本，经验超阈率分别为 0.1029 和 0.1022。

表 2 中， n_u 为超过 POT 尾部建模阈值 u_e 的样本数量， ξ_e 和 β_e 分别为 GPD 形状参数和尺度参数； x_e^* 表示目标人类驾驶重现水平在原始风险尺度上的取值， $\gamma_e^* = S_e(x_e^*)$ 表示同一安全关键水平在 EVT 风险尺度上的映射值。后续闭环评估将以 $R_e(X) \geq \gamma_e^*$ 作为安全关键判定条件。

表 2 POT-GPD 尾部模型拟合与 EVT 安全关键阈值标定结果
Table 2 POT-GPD tail-model fitting and EVT safety-critical threshold calibration

场景类型	样本数 n_u	POT 阈值 u_e	形状参数 ξ_e	尺度参数 β_e	原始阈值 x_e^*	EVT 阈值 γ_e^*
跟驰场景	7546	1.6873	0.1725	0.5497	4.7773	6.2037
切入场景	399	2.2216	0.0861	0.6473	4.6859	5.5739

图 3 和图 4 进一步检验两类风险样本的尾部区域、POT-GPD 尾部模型的拟合质量和阈值稳定性。




图 3 跟驰风险尾部的 POT-GPD 诊断

Fig. 3 POT-GPD diagnostics for car-following tail risk




图 4 切入风险尾部的 POT-GPD 诊断

Fig. 4 POT-GPD diagnostics for cut-in tail risk

图 3 和图 4 结果表明，两类风险样本在所选 POT 尾部建模阈值以上均具有可接受的

尾部拟合表现：经验生存函数与 POT-GPD 尾部生存函数在主要超阈区间内保持较好一致性，均值剩余寿命、参数稳定性和 PP 诊断均未显示明显的系统性偏差。其中，跟驰场景的 Kolmogorov–Smirnov、Cramér–von Mises 和 Anderson–Darling 检验的 p 值分别为 0.68、0.70 和 0.50；切入场景的对应 p 值分别为 0.23、0.13 和 0.19。上述结果说明，所拟合的 POT-GPD 尾部模型能够为后续人类驾驶校准的 EVT 安全关键阈值标定提供统计依据。




图 5 基于人类驾驶重现水平的 EVT 安全关键阈值标定

Fig. 5 EVT safety-critical threshold calibration from human-driving return levels

图 5 给出了目标风险重现里程与 EVT 安全关键阈值之间的标定结果。可以看到，在同一场景内，目标风险重现里程越大，对应的人类驾驶尾部超越频率越低，反解得到的安全关键阈值也越高。

在本文设定下，跟驰场景的 300 km 重现水平对应 $\gamma_{cf}^* = 6.2037$ ，切入场景的 3000 km 重现水平对应 $\gamma_{ci}^* = 5.5739$ 。两类场景的阈值差异反映了其风险尾部分布和事件暴露特征的不同。因此，后续闭环评估分别采用场景特异的 EVT 安全关键阈值，并以 $R_e(X) \geq \gamma_e^*$ 作为被测 ADS 在长尾测试分布 $\mathbb{P}_e$ 下达到对应场景人类驾驶校准安全关键风险水平的判定条件。

3.2 长尾测试分布的统计一致性

闭环评估输入 $X = (\mathbf{o}_e, z)$ 服从长尾测试分布 $\mathbb{P}_e = \mathcal{D}_e \otimes \mathcal{N}(0, I)$ 。其中，场景条件 $\mathbf{o}_e$ 从由 *highD* 尾部事件条件样本拟合得到的高斯 Copula 分布 $\mathcal{D}_e$ 中采样；目标车动作序列则由预训练条件扩散模型 $G_\theta(\mathbf{o}_e, z)$ 在确定性 DDIM 解码下生成。跟驰场景生成 125 步纵向加速度 (jerk) 序列，对应 5.0 s 目标车运动，并将 $|\text{jerk}|$ 约束在 12 m/s^3 以内；切入场景生成 100 步二维加速度序列，对应 4.0 s 交互过程，并约束 $a_x \in [-8, 4] \text{ m/s}^2$ 、 $|a_y| \leq 4 \text{ m/s}^2$ 。因此，跟驰和切入场景中闭环评估用例 $X = (\mathbf{o}_e, z)$ 的维度分别为 132 和 210。跟驰和切入模型分别训练 250 和 1000 个 epoch，学习率采用余弦退火策略，最小学习率为 5×10^{-5} ；闭环评估阶段统一采用 50 步确定性 DDIM 解码。

图 6 表明，跟驰场景中由 Copula 采样得到的条件变量和由扩散模型生成的目标车轨迹，均与 *highD* 尾部事件样本保持较好统计一致性。其中初始间距、初始相对速度、前车速度变化和制动持续时间等场景条件边缘分布与经验尾部样本高度一致，例如初始间距和初始相对速度的 D_{KS} (Kolmogorov–Smirnov 距离，用于度量一维边缘分布差异) 分别为 0.0077 和 0.0074，制动持续时间的 D_{KS} 为 0.0088。所生成前车的初末速度、纵向位移和制动持续时间也与经验尾部轨迹接近，说明生成轨迹保留了与跟驰风险形成直接相关的运动特征，包括车距压缩、相对速度变化和前车减速过程。生成轨迹的加速度包络略宽，jerk 分布也更分散，说明扩散模型在满足尾部条件约束的同时引入了更宽的动作变化范围，而不是对原始轨迹进行逐条复刻。

进一步地，经验尾部条件样本与高斯 Copula 采样样本之间，7 维条件变量 Pearson 相关

矩阵非对角元素的平均绝对误差和最大绝对误差分别为 0.0241 和 0.0606；Spearman 相关矩阵的对应误差分别为 0.0175 和 0.0686。这表明场景条件的概率分布在保持边缘分布的同时，也较好再现了跟驰尾部条件变量之间的主要联合依赖关系。




图 6 跟驰长尾测试分布的条件变量与生成轨迹统计一致性

Fig. 6 Statistical consistency of condition variables and generated trajectories in the car-following long-tail test distribution

注：蓝色为 *highD* 尾部事件样本，橙色为由 $\mathbb{P}_e$ 采样并经扩散解码得到的生成样本； W_1 和 D_{KS} 分别为一维边缘分布的 Wasserstein-1 距离和 Kolmogorov-Smirnov 距离。




图 7 切入长尾测试分布的条件变量与生成轨迹统计一致性

Fig. 7 Statistical consistency of condition variables and generated trajectories in the cut-in long-tail test distribution

注：颜色和距离符号含义同图 6。

图 7 表明，切入场景的条件变量分布同样得到较好再现：初始速度、初始横向偏移、初始相对速度、跨线时间和目标车速度变化等条件变量的 D_{KS} 都低于 0.052，目标车速度变化

的 D_{KS} 为 0.0175。扩散模型所生成的轨迹保持了切入方向、横向位移和纵向位移的主要形态。其中车道进入率和进入后保持率均为 1.000，高于经验尾部样本中的 0.972 和 0.922，说明切入语义约束有效提高了闭环测试样本的可执行性。同时，生成轨迹在跨线时间、终端横向偏移和纵向位移等指标上保持了与经验尾部样本相近的变化范围。对于切入场景的 10 维条件变量，经验尾部条件样本与高斯 Copula 采样样本之间，Pearson 相关矩阵非对角元素的平均绝对误差和最大绝对误差分别为 0.0352 和 0.1004；Spearman 相关矩阵的对应误差分别为 0.0221 和 0.1629。尽管个别秩相关关系存在一定偏差，但是结合边缘 KS 距离结果可见，场景条件的概率分布仍保留了切入尾部条件变量之间的主要联合依赖结构。

总体而言， $\mathbb{P}_e$ 在尾部条件变量、主要联合依赖关系和目标车运动统计上与 *highD* 尾部事件保持较好统计一致性，同时允许生成轨迹在物理约束范围内形成必要的动作泛化。

3.3 长尾测试分布下的稀有风险估计

本节比较直接 Monte Carlo 与子集模拟对安全关键条件概率 $\hat{p}_e$ 的估计结果。根据式 (12)， $\hat{p}_e$ 表示被测 ADS 在长尾测试分布 $\mathbb{P}_e$ 下达到由 γ_e^* 定义的安全关键风险水平的条件概率。随后，本文按照式 (14) 将 $\hat{p}_e$ 与 *highD* 同类尾部事件暴露率 ρ_e 相乘，得到 ADS 安全关键风险强度 $\hat{\lambda}_e$ ，并以 $1/\hat{\lambda}_e$ 表示对应的风险重现里程。

直接 Monte Carlo 在跟驰和切入场景中分别执行 200000 和 10000 次闭环评估；子集模拟的每层样本数 N 、中间事件条件概率 p_0 和潜变量扰动标准差 σ_p 分别设为 (3000, 0.2, 0.12) 和 (1000, 0.1, 0.10)。跟驰场景的上下文刷新概率 $q_c = 0.7$ 、每样本最大转移尝试次数为 6；切入场景对应 $q_c = 0.5$ 、最大转移尝试次数为 4。表中相对标准误 (relative standard error, RSE) 采用最终层安全关键事件比例的二项近似计算，用于反映抽样的不确定性。




图 8 子集模拟过程中 EVT 风险得分分布的逐层迁移

Fig. 8 Layer-wise migration of EVT risk-score distributions during subset simulation

注：红色虚线为 EVT 安全关键阈值 γ_e^* ，阴影区域表示满足 $R_e(X) \geq \gamma_e^*$ 的安全关键区域。

图 8 展示了子集模拟过程中 EVT 风险得分向高风险区域迁移的结果。跟驰场景中，得分 p90/p95 从第 0 层的 4.3884/4.8748 增至最终层的 6.6739/6.7119，安全关键样本比例由 0.00333 提升至 0.31133，说明子集模拟能够将样本有效集中到 γ_e^* 附近及其以上的高风险区域。切入场景中，得分 p90/p95 从 1.6855/3.0838 增至 5.0421/6.2271，安全关键样本比例由 0.0070 提升至 0.0680；与跟驰场景相比，切入场景最终层中超过 γ_e^* 的样本仍主要分布于右尾，表明其安全关键事件在长尾测试分布 $\mathbb{P}_e$ 下更加稀疏。

表 3 汇总了直接 Monte Carlo 与子集模拟的闭环估计结果。在跟驰场景中，200000 次独立 Monte Carlo 得到 $\hat{p}_e = 0.0024$ ，而子集模拟仅用 29303 次闭环评估得到 $\hat{p}_e = 0.0025$ ，两者概率估计接近；同时，RSE 从 0.0455 降至 0.0272，表明子集模拟在保持相同目标事件定义的同时显著降低了估计不确定性。按照独立 Monte Carlo 的 $N^{-1/2}$ 收敛关系估算，若达到相近 RSE 约需 5.61×10^5 次独立闭环仿真，按闭环调用次数计，相当于约 19.2 倍的等精度

表 3 闭环安全关键概率与风险重现里程估计

Table 3 Closed-loop safety-critical probability and risk-return mileage estimates

场景	估计方法	闭环次数	安全关键条件概率 $\hat{p}_e$	相对标准误差	ADS 风险强度 $\hat{\lambda}_e/\text{km}$	ADS 风险重现里程/km
跟驰	MC	200000	0.0024	0.0455	4.089×10^{-4}	2445.62 (8.15)
跟驰	SS	29303	0.0025	0.0272	4.226×10^{-4}	2366.41 (7.89)
切入	MC	10000	0.0065	0.1236	5.831×10^{-5}	17148.89 (5.72)
切入	SS	3267	0.0068	0.1171	6.100×10^{-5}	16392.32 (5.46)

注：MC 表示 Monte Carlo，SS 表示子集模拟；括号内数值为 ADS 风险重现里程相对于 *highD* 人类驾驶目标重现里程的倍数。

评估加速。换算为里程归一化风险强度后，被测 ADS 在跟驰场景中的安全关键风险强度为 $4.226 \times 10^{-4}/\text{km}$ ，为 *highD* 人类驾驶基准 $3.333 \times 10^{-3}/\text{km}$ 的 12.68%，对应 ADS 风险重现里程为 2366.41 km，即 *highD* 目标重现里程的 7.89 倍。

在切入场景中，子集模拟以 3267 次闭环评估得到 $\hat{p}_e = 0.0068$ ，与 10000 次独立 Monte Carlo 得到的 0.0065 接近，且 RSE 基本相当。换算后，被测 ADS 的安全关键风险强度为 $6.100 \times 10^{-5}/\text{km}$ ，为 *highD* 人类驾驶基准 $3.333 \times 10^{-4}/\text{km}$ 的 18.30%，对应 ADS 风险重现里程为 16392.32 km，即 *highD* 目标重现里程的 5.46 倍。上述结果表明，在本文构造的长尾测试分布 $\mathbb{P}_e$ 及 *highD* 暴露换算口径下，被测 ADS 的安全关键风险强度显著低于 *highD* 自然驾驶行为。

4 讨论与分析

当前实验以 *highD* 高速公路跟驰与切入场景为主要对象，所得人类驾驶校准的 EVT 安全关键阈值 γ_e^* 、长尾测试分布 $\mathbb{P}_e$ 以及安全关键风险强度换算结果均受限于该数据集的道路类型、车辆类别和交互模式，后续应扩展到城市道路、匝道汇入、无保护转向和混合交通等更复杂运行设计域（operational design domain, ODD）。此外，本文以 *highway-env* 预设策略作为被测 ADS 案例，主要验证方法框架的可行性，未来需要在学习型端到端驾驶策略、规划控制系统和工业级 ADS 上进一步检验其测试能力。未来也可进一步引入考虑 MCMC 相关性的方差估计、更多重现水平下的敏感性分析以及多数据集交叉验证，以增强人类驾驶风险尾部度量基准的稳健性。

5 结论

本文针对自动驾驶长尾安全测试中自然驾驶参照不足、离线尾部事件难以闭环复现、安全关键条件概率估计效率低等问题，提出了一种以 *highD* 人类驾驶风险尾部为统计基准的长尾安全测试方法。该方法将自然驾驶尾部样本转化为可采样的长尾测试分布，并以 EVT 安全关键阈值 γ_e^* 统一安全关键事件判据，从而使被测 ADS 的安全关键条件概率、ADS 安全关键风险强度及其风险重现里程能够在同一统计口径下解释分析。实验表明，在高速公路交互场景中，本文方法能够稳定标定安全关键阈值，构建保持主要行为统计特征的长尾测试分布，并以少于直接 Monte Carlo 的闭环评估预算获得相近的稀有风险估计结果。在本文所构造的长尾测试分布和风险暴露换算口径下，被测 ADS 的风险强度显著低于 *highD* 人类驾驶基准。本文方法能够把有限自然驾驶尾部观测转化为具有闭环可执行性和概率可解释性的安全测试证据，为自动驾驶系统的长尾风险评估提供方法支撑。

参考文献

- [1] DYRO R, FOUTTER M, LI R, et al. Realistic Extreme Behavior Generation for Improved AV Testing[C/OL]//2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 1354-1362. <https://arxiv.org/abs/2409.10669>. DOI: [10.1109/ICRA55743.2025.11128450](https://doi.org/10.1109/ICRA55743.2025.11128450).
- [2] 蒋拯民, 党少博, 李慧云, 等. 自动驾驶汽车场景测试研究进展综述[J/OL]. 汽车技术, 2022(8): 10-22. DOI: [10.19620/j.cnki.1000-3703.20211088](https://doi.org/10.19620/j.cnki.1000-3703.20211088).
- [3] WANG J, PUN A, TU J, et al. AdvSim: Generating Safety-Critical Scenarios for Self-Driving Vehicles[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 9909-9918. DOI: [10.1109/CVPR46437.2021.00978](https://doi.org/10.1109/CVPR46437.2021.00978).
- [4] HANSELMANN N, RENZ K, CHITTA K, et al. King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients[C/OL]//European Conference on Computer Vision. Springer, 2022: 335-352. DOI: [10.1007/978-3-031-19839-7_20](https://doi.org/10.1007/978-3-031-19839-7_20).
- [5] FENG L, LI Q, PENG Z, et al. Trafficgen: Learning to generate diverse and realistic traffic scenarios[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3567-3575. DOI: [10.1109/ICRA48891.2023.10160296](https://doi.org/10.1109/ICRA48891.2023.10160296).
- [6] SUN S, GU Z, SUN T, et al. Drivescenegen: Generating diverse and realistic driving scenarios from scratch[J/OL]. IEEE Robotics and Automation Letters, 2024, 9(8): 7007-7014. DOI: [10.1109/LRA.2024.3416792](https://doi.org/10.1109/LRA.2024.3416792).
- [7] ZHONG Z, REMPE D, XU D, et al. Guided conditional diffusion for controllable traffic simulation[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3560-3566. DOI: [10.1109/ICRA48891.2023.10161463](https://doi.org/10.1109/ICRA48891.2023.10161463).
- [8] JIANG M, BAI Y, CORNMAN A, et al. Scenediffuser: Efficient and controllable driving simulation initialization and rollout[C/OL]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 55729-55760. DOI: [10.52202/079017-1771](https://doi.org/10.52202/079017-1771).
- [9] XIE Y, GUO X, WANG C, et al. AdvDiffuser: Generating Adversarial Safety-Critical Driving Scenarios via Guided Diffusion[C/OL]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2024: 9983-9989. DOI: [10.1109/IROS58592.2024.10802408](https://doi.org/10.1109/IROS58592.2024.10802408).
- [10] XU C, PETIUSHKO A, ZHAO D, et al. DiffScene: Diffusion-Based Safety-Critical Scenario Generation for Autonomous Vehicles[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(8): 8797-8805. DOI: [10.1609/aaai.v39i8.32951](https://doi.org/10.1609/aaai.v39i8.32951).
- [11] JIANG Z, LIU J, SUN P, et al. Generation of Risky Scenarios for Testing Automated Driving Visual Perception Based on Causal Analysis[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(11): 15991-16004. DOI: [10.1109/TITS.2024.3421343](https://doi.org/10.1109/TITS.2024.3421343).
- [12] 赵祥模, 赵玉钰, 景首才, 等. 面向自动驾驶测试的危险变道场景泛化生成[J/OL]. 自动化学报, 2023, 49(10): 2211-2223. DOI: [10.16383/j.aas.c220772](https://doi.org/10.16383/j.aas.c220772).

- [13] 朱宇, 徐志刚, 赵祥模, 等. 基于 TsGAN 的自动驾驶汽车高速公路变道切入测试场景自动生成算法[J/OL]. 华南理工大学学报 (自然科学版), 2024, 52(8): 76-88. DOI: [10.12141/j.issn.1000-565X.230229](https://doi.org/10.12141/j.issn.1000-565X.230229).
- [14] YAN X, ZOU Z, FENG S, et al. Learning naturalistic driving environment with statistical realism[J/OL]. Nature Communications, 2023, 14: 2037. DOI: [10.1038/s41467-023-37677-5](https://doi.org/10.1038/s41467-023-37677-5).
- [15] HAO K, CUI W, LUO Y, et al. Adversarial safety-critical scenario generation using naturalistic human driving priors[J/OL]. IEEE Transactions on Intelligent Vehicles, 2024, 9(9): 5392-5406. DOI: [10.1109/TIV.2023.3335862](https://doi.org/10.1109/TIV.2023.3335862).
- [16] REN K, YANG J, LU Q, et al. Intelligent testing environment generation for autonomous vehicles with implicit distributions of traffic behaviors[J/OL]. Transportation Research Part C: Emerging Technologies, 2025, 174: 105106. DOI: [10.1016/j.trc.2025.105106](https://doi.org/10.1016/j.trc.2025.105106).
- [17] FENG S, YAN X, SUN H, et al. Intelligent driving intelligence test for autonomous vehicles with naturalistic and adversarial environment[J/OL]. Nature Communications, 2021, 12: 748. DOI: [10.1038/s41467-021-21007-8](https://doi.org/10.1038/s41467-021-21007-8).
- [18] FENG S, SUN H, YAN X, et al. Dense reinforcement learning for safety validation of autonomous vehicles[J/OL]. Nature, 2023, 615: 620-627. DOI: [10.1038/s41586-023-05732-2](https://doi.org/10.1038/s41586-023-05732-2).
- [19] ZHANG S, JIANG Z, SANG M, et al. A Comprehensive Survey on Driving Compliance Assessment Methodologies for Autonomous Vehicles[J/OL]. IEEE Intelligent Transportation Systems Magazine, 2025, 17(4): 56-82. DOI: [10.1109/MITS.2025.3548869](https://doi.org/10.1109/MITS.2025.3548869).
- [20] ZHANG H, SUN J, TIAN Y. Accelerated safety testing for highly automated vehicles: Application and capability comparison of surrogate models[J/OL]. IEEE Transactions on Intelligent Vehicles, 2024, 9(1): 2409-2418. DOI: [10.1109/TIV.2023.3319158](https://doi.org/10.1109/TIV.2023.3319158).
- [21] KRAJEWSKI R, BOCK J, KLOEKER L, et al. The highD Dataset: A Drone Dataset of Naturalistic Vehicle Trajectories on German Highways for Validation of Highly Automated Driving Systems[C/OL].//2018 21st International Conference on Intelligent Transportation Systems (ITSC). 2018: 2118-2125. DOI: [10.1109/ITSC.2018.8569552](https://doi.org/10.1109/ITSC.2018.8569552).
- [22] JIANG Z, PAN W, LIU J, et al. Efficient and unbiased safety test for autonomous driving systems[J/OL]. IEEE Transactions on Intelligent Vehicles, 2023, 8(5): 3336-3348. DOI: [10.1109/TIV.2022.3213310](https://doi.org/10.1109/TIV.2022.3213310).
- [23] DAVISON A C, HUSER R. Statistics of Extremes[J/OL]. Annual Review of Statistics and Its Application, 2015, 2: 203-235. <https://www.annualreviews.org/content/journals/10.1146/annurev-statistics-010814-020133>.
- [24] ÅSLJUNG D, NILSSON J, FREDRIKSSON J. Using Extreme Value Theory for Vehicle Level Safety Validation and Implications for Autonomous Vehicles[J/OL]. IEEE Transactions on Intelligent Vehicles, 2017, 2(4): 288-297[2026-05-26]. <https://ieeexplore.ieee.org/abstract/document/8094027>. DOI: [10.1109/TIV.2017.2768219](https://doi.org/10.1109/TIV.2017.2768219).
- [25] AU S K, PATELLI E. Rare event simulation in finite-infinite dimensional space[J/OL]. Reliability Engineering & System Safety, 2016, 148: 67-77. DOI: [10.1016/j.res.2015.11.012](https://doi.org/10.1016/j.res.2015.11.012).